

Networked Influence in a Tabula Rasa Legislature — Reporte del estudio

Redes de co-patrocinio, dinámicas ideológicas y éxito político en la Convención Constitucional de Chile (2021–2022)

A. Olivera, J. Fábrega

July 7, 2026

Contents

1. Propósito de este documento	2
2. Objetivos del proyecto	2
2.1 Contexto: la Convención Constitucional como experimento natural	2
2.2 Preguntas de investigación	2
2.3 Marco teórico	3
2.4 Diseño: tres modelos	3
3. Datos	4
3.1 Fuentes primarias (estado objetivo, post-actualización)	4
3.2 Esquema de los datos de trazabilidad	5
3.3 Datos usados por la versión vigente (pre-actualización)	6
4. Pipeline y resultados vigentes	6
4.1 Scripts	6
4.2 Resultados vigentes (extended abstract, abril 2026)	7
5. Problemas identificados (registro detallado)	7
P1 — Cobertura incompleta de comisiones [ABIERTO — motivo central de la actualización]	7
P2 — Definición de lazo inconsistente entre comisiones [ABIERTO — decisión tomada]	7
P3 — Reproducibilidad rota: rutas hardcodeadas a carpetas legacy de otro repositorio [PARCIAL — infraestructura lista 2026-07-07; recableado de scripts en la próxima iteración]	8
P4 — Normalización de nombres fragmentada (bug de las 155 filas) [ABIERTO]	8
P5 — Perfiles BCN incompletos [RESUELTO 2026-07-07]	8
P6 — Selección sobre la variable dependiente en M3 (ART-FALLIDO) [ABIERTO — decisión tomada]	9
P7 — Mapeo génesis→final recalculado desde insumos legacy [ABIERTO — decisión tomada]	10
P8 — Heterogeneidades residuales en dataverse-final [PARCIAL — la mayoría resuelta aguas arriba 2026-07-07]	10
P9 — <i>W</i> y centralidades de M3 medidas sobre la red posterior al resultado [ABIERTO — decisión tomada]	10
P10 — dynIRT sin errores estándar [ABIERTO — prioridad baja]	11
P11 — ERGMs por comisión sin convergencia plena [ABIERTO]	11
P12 — Sin exportación de figuras ni tablas [ABIERTO]	11
P13 — Errores y desactualizaciones en los documentos del paper [ABIERTO]	11
P14 — Copias de insumos desincronizadas entre repos [RESUELTO 2026-07-07]	11

P15 — C2 sin autores: no podía entrar a la red de co-patrocinio [RESUELTO aguas arriba 2026-07-07, ronda 2]	11
---	----

6. Decisiones de diseño confirmadas	12
7. Plan de actualización	13
8. Registro de cambios de este documento	13

1. Propósito de este documento

Este es el **reporte vivo** del proyecto: se actualiza a medida que el estudio avanza y registra, en un solo lugar, (i) los objetivos y el marco teórico, (ii) los datos y su procedencia exacta, (iii) el pipeline y los resultados vigentes, (iv) los **problemas identificados y su estado de resolución**, (v) las decisiones de diseño confirmadas, y (vi) el plan de trabajo. La versión v1 (julio 2026) documenta el estado del proyecto al momento de iniciar la **actualización de 5 a 7 comisiones** con los datos limpios de `dataverse-final` (PR #4 del repositorio de datos).

Convenciones: los problemas se etiquetan P1, P2, ... con estado [ABIERTO], [RESUELTO] o [PARCIAL]. Las rutas relativas refieren a este repositorio; el repositorio de datos se abrevia CPT (= B - constitutional-proposal-tracking, en <https://github.com/aoliveram/constitutional-proposal-tracking>).

2. Objetivos del proyecto

2.1 Contexto: la Convención Constitucional como experimento natural

La Convención Constitucional chilena (julio 2021 – julio 2022) es un caso excepcionalmente limpio para estudiar la **génesis de redes políticas**. A diferencia de una legislatura ordinaria, donde las redes de colaboración observadas son el sedimento de décadas de carreras compartidas, disciplinas de partido y expectativas de reelección, la Convención partió de un cuasi-*tabula rasa* organizacional:

1. **Actores mutuamente desconocidos.** De los 155 escaños, una mayoría inédita correspondió a independientes y outsiders sin trayectoria parlamentaria, electos por listas ad hoc y escaños reservados para pueblos originarios (17). Gran parte de los delegados no se conocía entre sí ni compartía socialización partidaria.
2. **Sin jerarquías heredadas.** No existían comités con seniority, liderazgos de bancada consolidados ni “sombra del futuro” electoral común: el órgano se disolvía al entregar el texto.
3. **Reglas endógenas.** La Convención escribió su propio reglamento, incluyendo el mecanismo central que explota este estudio: toda **iniciativa convencional constituyente** requería el patrocinio de **al menos 8 y no más de 16 convencionales** (Reglamento General, art. 83). El piso obliga a formar coaliciones mínimas para participar del proceso; el techo impide que las firmas se diluyan en mega-bloques y convierte cada patrocinio en un recurso escaso y estratégico.
4. **Horizonte comprimido.** Todo el ciclo — formación de lazos, negociación, producción normativa y resultado (el borrador del 14-05-2022) — ocurre en ~10 meses y está íntegramente documentado, con autoría explícita en cada iniciativa e indicación.

El co-patrocinio es, por tanto, un **proxy observable, costoso y fechado de colaboración política**, y la Convención permite observar el ciclo completo: cómo se forman los lazos entre extraños (RQ1), qué hacen esos lazos con las posiciones de los actores (RQ2), y cómo la posición en la red se traduce en éxito sobre el texto final (RQ3).

2.2 Preguntas de investigación

- **RQ1 — Formación.** ¿Qué factores impulsan la formación de la red de co-patrocinio cuando no existen jerarquías previas? ¿Domina la homofilia clásica (afiliación, género) o aparecen estrategias de diversificación?

- **RQ2 — Influencia vs. selección.** ¿La exposición a los co-autores desplaza las posiciones ideológicas de los delegados (influencia social), o los delegados seleccionan co-autores ya afines (selección endógena)?
- **RQ3 — Éxito.** ¿Cómo predice la estructura de red el éxito político individual, operacionalizado como **retención léxica**: cuánto del texto que un delegado patrocinó sobrevive en el borrador constitucional final?

2.3 Marco teórico

(Apartado en construcción: esta sección fija el esqueleto argumental y se irá puliendo junto con la especificación final de los modelos.)

(a) Formación de lazos en legislaturas: homofilia y sus límites. La literatura de co-sponsorship en legislaturas consolidadas (Fowler 2006; Bratton & Rouse 2011; Kirkland 2011) documenta con robustez que los lazos siguen líneas de partido, región y género — homofilia en el sentido de McPherson, Smith-Lovin & Cook (2001). Pero esa literatura no puede separar cuánto de la homofilia observada es preferencia y cuánto es estructura heredada (comités, bancadas, historia). La Convención remueve la estructura heredada: lo que se observe en la formación temprana refleja preferencias y estrategias de actores en un campo casi vacío. **H1a (línea base):** persiste homofilia por afiliación política agrupada, el clivaje más visible incluso entre independientes.

(b) Gatekeeping estratégico: la homofilia negativa de los “dotados”. Para los actores con recursos escasos y transversalmente valiosos — pericia jurídica (abogados, en una asamblea cuyo producto es un texto legal) y experiencia institucional previa — la teoría de brokerage (Burt 1992; Padgett & Ansell 1993) predice lo contrario de la homofilia: maximizan influencia **dispersándose** entre coaliciones, ocupando agujeros estructurales en vez de agruparse entre sí. Se comportan como *gatekeepers* del conocimiento procedimental. **H1b:** abogados y delegados con experiencia institucional exhiben homofilia *negativa* (co-patrocinan menos entre sí de lo esperado), condicional en los demás términos del modelo.

(c) Influencia social vs. selección endógena. Que los conectados se parezcan ideológicamente admite dos mecanismos generativos: influencia (los lazos mueven las posiciones; Friedkin & Johnsen 1990) o selección (las posiciones crean los lazos). Distinguirlos es el problema clásico de la econometría de redes (Shalizi & Thomas 2011; en la tradición SAOM, Steglich, Snijders & Pearson 2010). Nuestra estrategia: panel con efectos fijos individuales (toda heterogeneidad estable del delegado queda absorbida) más un **test de falsificación** con exposición futura (*lead*): si el efecto contemporáneo fuera influencia causal, la exposición futura no debería “predecir” el cambio pasado. **H2:** en un cuerpo con posiciones ideológicas pre-formadas (los delegados llegan con identidades políticas adultas), domina la selección; el efecto de exposición desaparece bajo efectos fijos.

(d) El éxito legislativo como fenómeno colectivo. La efectividad legislativa suele tratarse como atributo individual (Volden & Wiseman 2014). Pero si la unidad de producción es la coalición firmante — y el reglamento fuerza que lo sea — el éxito debería *derramarse* por los lazos de co-autoría: mi retención léxica depende de la retención de aquellos con quienes escribo. Econométricamente eso es autocorrelación espacial en la variable de resultado sobre la topología de la red, y el marco natural son los modelos espaciales sobre redes (LeSage & Pace 2009). **H3:** la retención léxica exhibe dependencia de red fuerte; los modelos con rezago espacial (SAR/SDM) dominan al OLS, y el componente indirecto (spillover) de los efectos es sustantivo.

(e) Anclaje ideológico. Las posiciones ideológicas se estiman desde el comportamiento de votación nominal con un modelo dinámico de puntos ideales (dynIRT; Martin & Quinn 2002; implementación **emIRT** de Imai, Lo & Olmsted 2016), con prior de caminata aleatoria ($\omega^2 = 0.025$) y anclaje por dos delegados de posición pública inequívoca (Marinovic a la derecha, Baradit a la izquierda). Resultado: matriz $\Theta \in \mathbb{R}^{154 \times 91}$ (delegados $\times$ períodos de votación, 2021-07-13 a 2022-06-24).

2.4 Diseño: tres modelos

M1 — Formación (Valued ERGM). Red pooled de co-patrocinio con pesos $w_{ij} = n^\circ$ de documentos co-firmados. ERGM valuado con referencia Poisson:

$$P(W = w) \propto \exp\{\theta^\top g(w)\}, \quad g = (\text{sum}, \text{nodematch}_{\text{afiliación, abogado, experiencia, género}}, \text{absdiff}_{\text{edad, grado}}, \text{nodecov}_{\text{edad}})$$

Los términos **nodematch** capturan homofilia (H1a) y su reverso (H1b). El término **absdiff** sobre el **grado académico** (escala ordinal 0–3: sin estudios universitarios terminados / educación superior terminada / magíster / doctorado; decisión 2026-07-07) prueba estratificación por credenciales educativas: un coeficiente negativo indica que la distancia educativa inhibe la co-firma.

M2 — Dinámica ideológica (panel FE). Sobre ondas temporales por comisión:

$$\Delta\theta_{i,t} = \alpha_i + \beta_1\theta_{i,t-1} + \beta_3 \text{NetExp}_{i,t-1} + \varepsilon_{it}, \quad \text{NetExp}_{i,t-1} = \frac{\sum_{j \neq i} w_{ij,t-1} \theta_{j,t-1}}{\sum_{j \neq i} w_{ij,t-1}}$$

con $w_{ij,t-1}$ = co-firmas acumuladas hasta la onda $t-1$. Comparación OLS agrupado vs. efectos fijos (within) vs. aleatorios (Hausman), errores agrupados por delegado, y falsificación con *lead*.

M3 — Éxito (Spatial Durbin Model). Con y_i = retención léxica media del delegado (similitud coseno TF-IDF génesis→final; robustez con Sentence-BERT) y W = matriz de co-autoría row-normalizada:

$$y = \rho W y + X\beta + W X \gamma + \varepsilon$$

Se compara OLS/SAR/SEM/SDM (AIC, Moran’s I) y se descomponen efectos directos/indirectos/totales.

3. Datos

3.1 Fuentes primarias (estado objetivo, post-actualización)

Desde 2026-07-07 los datos viven como **snapshot versionado dentro de este repositorio** (`data/raw/dataverse-final/`, copiado de CPT **paper-draft @ 5852519**; ver P14). El test de aceptación `code/0a-verify-dataverse-snapshot.py` valida cada refresco y escribe **QA-report.txt**.

Fuente	Ubicación	Contenido	N
Iniciativas génesis	<code>data/raw/dataverse-final/comisiones-originales/C{k}_GENESIS_master.json</code>	comisiones originales aprobadas en general	892
Trazabilidad completa	<code>.../C{k}_TRACK_full.json</code>	Artículos (incl. fallidos) con <code>authors</code> , <code>history[]</code> fechado y <code>final_status</code> al 100%	2.019
Trazabilidad filtrada	<code>.../C{k}_TRACK_articles.json</code>	Sólo artículos presentes en el borrador final	478
Borrador final	<code>.../C{k}_BORRADOR_final.json</code>	Artículos del borrador del 14-05-2022, por comisión	498
Mapeo maestro	<code>data/raw/dataverse-final/198-comitidos-finales-comisiones.csv</code>	198 comitidos finales, fuente(s): 298 identical, 146 similar, 54 not_traced	498
Codebook	<code>data/raw/dataverse-final/dataverse-codebook-draft.md</code>	Sección de <code>article_uid</code> , <code>final_status</code> , <code>timestamp</code>	—
Nombres canónicos	<code>data/raw/convention_members.json</code>	Referencia oficial “Apellido, Nombre”	154
Perfiles curados	<code>data/raw/conventional-profiles.json</code> (imputado dual-fuente; ver P5)	Características: género, afiliación, distrito, abogado, edad, grado (0–3), experiencia	154

Fuente	Ubicación	Contenido	N
Puntos ideales	<code>data/raw/emirt/</code>	Salidas dynIRT: Θ 154×91, metadata, posiciones resumen	154×91

Desglose por comisión del snapshot (TRACK_full = artículos + indicaciones sueltas; entre paréntesis, artículos con **authors**, la base de la red de co-patrocinio):

Comisión	Nombre oficial (corto)	GENESIS	BORRADOR	TRACK_article	TRACK_full	Artículos (con authors)	Ind. sueltas
C1	Sistema Político	96	100	131	202	99 (99)	103
C2	Principios Constitucionales	312	41	24	182	182 (149)	0
C3	Forma de Estado	222	96	72	234	222 (222)	12
C4	Derechos Fundamentales	167	58	58	175	167 (150)	8
C5	Medio Ambiente	464	43	36	484	464 (420)	20
C6	Sistemas de Justicia	440	119	117	491	447 (418)	44
C7	Sistemas de Conocimientos	191	41	40	251	228 (218)	23
Total		1.892	498	478	2.019	1.809 (1.676)	210

(Cifras post-ronda 2 de CPT (6fac4c4): **authors** de C2 poblado vía **sources**→firmantes de las iniciativas y de C4 vía **icc_id**, reglas validadas 1.415/1.416; el residuo de 134 registros sin autores queda documentado en el codebook — 65 de iniciativas populares/indígenas, 45 de ICC no recuperadas, 24 sin referencia de fuente.)

Nombres oficiales completos de las comisiones (verificados 2026-07-06 contra el registro oficial `cconstituyente.cl`, Wikipedia y UNESCO; ver P13):

1. Sistema Político, Gobierno, Poder Legislativo y Sistema Electoral
2. Principios Constitucionales, Democracia, Nacionalidad y Ciudadanía
3. Forma de Estado, Ordenamiento, Autonomía, Descentralización, Equidad, Justicia Territorial, Gobiernos Locales y Organización Fiscal
4. Derechos Fundamentales
5. Medio Ambiente, Derechos de la Naturaleza, Bienes Naturales Comunes y Modelo Económico
6. Sistemas de Justicia, Órganos Autónomos de Control y Reforma Constitucional
7. Sistemas de Conocimientos, Culturas, Ciencia, Tecnología, Artes y Patrimonios

3.2 Esquema de los datos de trazabilidad

Cada registro de artículo en TRACK_full contiene: **article_uid** (identificador único, guiones bajos), **article**, **timestamp** (formato MM-DD), **text**, **sources** (iniciativas de origen), **authors** (array "Apellido, Nombre"), **final_status** ("Idéntico a N.- ..." / "Similar a N.- ..." / "ART-FALLIDO"),

y `history[]`. Cada entrada de `history[]` es una **indicación** fechada: `timestamp`, `step`, `number`, `authors`, `action` (ADD/DELETE/...), `target_scope`, `content`, `content_to_remove`, `placement_instructions`, `content_snapshot`.

Hechos estructurales que el pipeline absorbe (detalle en P8/P15):

- El esquema del GENESIS sigue **heterogéneo** entre comisiones (C1/C2/C3 sin `article_uid`; C4 sin `article/sources`; `authors` intermitente) — homogeneización pendiente en CPT; el loader unifica.
- Todos los `TRACK_full` salvo C2 contienen **“indicaciones sueltas”** (210 en total): registros de indicación al nivel superior con `action`, sin anclar a un artículo; 205/210 traen `authors` + `timestamp` y alimentan las ondas de M2. Los títulos de capítulo de C1 fueron eliminados aguas arriba (2026-07-07).
- `step` está normalizado a "Indicacion" (2.763 menciones; C2 conserva sus etiquetas de etapa propias). `timestamp` es MM-DD[-bloque] con año implícito 2022; hay 66 NA a nivel superior (C1 4, C3 2, C5 5, C6 17, C7 38) y 5 anidados.
- Los `authors` incluyen referencias a **iniciativas populares** (“7-2”, “Iniciativa Popular Indígena 21-2”): `code/lib_names.py` las clasifica como no-persona y las excluye de la red. Con esas reglas, las **75.616 menciones de autor-persona resuelven al 100%** contra los 154 canónicos (QA 0a, post-ronda 2).

3.3 Datos usados por la versión vigente (pre-actualización)

La versión reflejada en el extended abstract (abril 2026) usa insumos **anteriores** al PR #4 de limpieza, copiados en `data/raw/commissions/` (5 archivos: C1, C3, C5, C6, C7, enriquecidos a mano) y redes pre-construidas en `data/raw/network-visualization/`. Cifras vigentes: red pooled de **7.162 aristas**, **154 nodos**, **peso total 202.765**, **peso máximo 480**; ondas dinámicas solo para C1 (5), C3 (8) y C5 (6); mapeo génesis→final de **236 artículos** (125 idénticos + 111 similares; C1: 131, C3: 71, C5: 34); panel de **2.926** observaciones delegado-período; SDM sobre **141** casos completos.

4. Pipeline y resultados vigentes

4.1 Scripts

#	Script	Rol	Outputs
00	<code>code/00-build_dynamic_networks.py</code>	Redes de co-autoría (pooled + ondas C1/C3/C5)	<code>pooled_cumulative_network.csv</code> , <code>{C}_dynamic_networks.json</code>
01	<code>code/01-model-valued-ergm.py</code>	M1: Valued ERGM Poisson + centralidades	<code>ergm_pooled_results.rds</code> , <code>network_metrics.csv</code>
02	<code>code/02-extract-emirt-temporal.py</code>	Abstracción temporal $\Theta \leftrightarrow$ ondas de comisión	<code>emirt_*.csv</code>
03	<code>code/03-model-network-influence.py</code>	M2: Exposición de red + panel FE/RE/OLS	<code>network_exposure_panel.csv</code> , <code>panel_regression_results.rds</code>
04	<code>code/04-build-article-mapping.py</code>	M3: Mapeo artículos comisión → borrador final	<code>article_mapping_unified.{json,csv}</code>
05	<code>code/05-nlp-text-similarity.py</code>	Retención léxica TF-IDF + SBERT	<code>article_similarity_scores.csv</code> , <code>author_success_scores.csv</code>
06	<code>code/06-build-integrated-dataset.py</code>	M4: Integración de datos	<code>integrated_dataset.{csv,json}</code>
07	<code>code/07-model-spatial-durbin.py</code>	M5: M3 + Moran, OLS/SAR/SEM/SDM, impactos	<code>sdm_results.rds</code> , <code>sdm_impacts.csv</code>
08	<code>code/08-robustness-checks.py</code>	Robustez de M1–M3	<code>robustness_results.rds</code>

4.2 Resultados vigentes (extended abstract, abril 2026)

- **M1.** `nodematch(afiliación)` = +0.41; `nodematch(abogado)` = -0.09; `nodematch(experiencia)` = -0.12; `nodematch(mujer)` = +0.08; `nodecov(edad)` = -0.024. Lectura: homofilia positiva de afiliación y género; **homofilia negativa** de abogados y experimentados (gatekeeping estratégico, H1b confirmada).
- **M2.** OLS agrupado: $\hat{\beta}_3 = +0.033$ ($p < 0.001$); efectos fijos: $\hat{\beta}_3 = +0.0004$ ($p = 0.91$); Hausman $\chi^2 = 784.96$ ($p < 0.001$) → FE. Falsificación con *lead* significativa ($p < 0.001$) → **selección, no influencia** (H2 confirmada).
- **M3.** Moran's $I = 0.155$ ($p < 10^{-6}$). AIC: OLS -338.5 < SEM -354.8 ($\lambda = 0.81$) < SAR -355.3 ($\rho = 0.89$) < **SDM** -383.4 ($\hat{\rho} = 0.997$). En OLS: `theta_mean` +0.012 ($p = 0.008$), `theta_sd` -0.103 ($p = 0.015$), `ego_heterophily` -0.063 ($p = 0.027$); centralidades n.s. Validación de medida: artículos “idénticos” puntúan 0.979 en TF-IDF. Robustez: SBERT preserva signos; con W binaria ρ cae a 0.374 manteniendo significancias clave (H3 confirmada).

5. Problemas identificados (registro detallado)

Esta sección es el inventario completo de defectos, deudas y decisiones pendientes detectados en la auditoría de julio 2026 (previa a la actualización). Es la lista de control contra la cual se ejecutará el plan de la §7.

P1 — Cobertura incompleta de comisiones [ABIERTO — motivo central de la actualización]

Situación. La versión vigente usa 5 de las 7 comisiones en M1 (C1, C3, C5, C6, C7; C2 y C4 ausentes del repo) y solo **3** en M2 y M3 (C1, C3, C5), porque los archivos antiguos de C6/C7 no tienen `final_status` ni ondas temporales. El propio abstract lo declara como limitación (“Ongoing work”).

Consecuencias. (i) La red pooled subestima lazos formados vía C2/C4 — con 312 y 167 iniciativas génesis, no son comisiones menores; C4 (Derechos Fundamentales) fue además la comisión políticamente más cargada. (ii) El mapeo de éxito cubre 236 de 498 artículos finales (47%): la DV de M3 ignora más de la mitad del borrador. (iii) El panel de M2 descarta la dinámica de 4 comisiones.

Solución. Migrar todo el pipeline a los `dataverse-final` de las 7 comisiones (PR #4 de CPT, mergeado): GENESIS para la red de co-patrocinio, `TRACK_full` para ondas e indicaciones, `coincidencias_comisiones.csv` + `BORRADOR_final` para el éxito.

P2 — Definición de lazo inconsistente entre comisiones [ABIERTO — decisión tomada]

Situación. En `code/00-build_dynamic_networks.py`, la red pooled suma la **última onda acumulada** de C1/C3/C5 (= génesis + **todas las indicaciones**, líneas 175–178) pero solo el génesis de C6/C7 (líneas 194–204). La red que estima M1 — y que M3 usa como W y para las centralidades — mezcla, por tanto, dos definiciones de lazo según la comisión.

Consecuencias. Los pesos no son comparables entre comisiones (C5 aporta 4.968 aristas acumuladas vs. C7 solo génesis); los coeficientes del ERGM confunden formación primaria con colaboración posterior.

Solución (decisión 2026-07-06). **M1 usará exclusivamente la red génesis** de las 7 comisiones: modela la *formación primaria* de lazos entre desconocidos, y el co-patrocinio de iniciativas es el acto fundacional (además, con umbral reglamentario 8–16 firmas, es un compromiso costoso y acotado). Las indicaciones entran solo a las **ondas acumuladas** de M2 (colaboración posterior, condicionada por la red ya formada). Para M3, ver P9. Robustez: red génesis+indicaciones como variante.

P3 — Reproducibilidad rota: rutas hardcodedas a carpetas legacy de otro repositorio [PARCIAL — infraestructura lista 2026-07-07; recableado de scripts en la próxima iteración]

Situación. Los scripts 02-05 leen desde rutas absolutas del repo CPT, y además desde carpetas legacy previas a la limpieza: 02-extract-emirt-temporal.R:10 (emIRT-analysis/, escribe a playground/research-proposal-implementation/data), 03-model-network-influence.R:30-32 (conventionals-bcn-webscrapping/, network-visualization/), 04-build-article-mapping.py:15-22 (comision-N/draft-after-indications-manual/, proposals/draft_final_text.json), 05-nlp-text-similarity.py:2. El archivo draft_final_text.json ni siquiera existe en este repositorio. Los scripts 00, 01, 06, 07, 08 sí leen de data/ local.

Consecuencias. El pipeline no corre de extremo a extremo desde este repo; los outputs commiteados en data/processed/ no son regenerables por terceros; y los insumos legacy quedaron desactualizados respecto de dataverse-final.

Solución (ejecutada 2026-07-07 en su mitad de infraestructura). Snapshot copiado a data/raw/dataverse-final/comision-{1..7}/ (CPT paper-draft @ 5852519, con README de procedencia y test de aceptación code/0a-verify-dataverse-snapshot.py); módulos centrales code/paths.py / code/paths.R creados. **Queda:** recablear los scripts 00-08 para que deriven todas sus rutas de esos módulos (se hará al reescribirlos en la actualización de modelos).

P4 — Normalización de nombres fragmentada (bug de las 155 filas) [ABIERTO]

Situación. El mapa NAME_CORRECTIONS (5 correcciones: Muñoz/Sepúlveda×2/Vargas-tipo/Chinga) vive solo en code/00-build_dynamic_networks.py:35-41. El pipeline de éxito (04→05→06) corre sin esa normalización, así que "Sepúlveda, Barbara" (con tilde, desde los archivos de comisión) no cruza con "Sepulveda, Barbara" (canónico) y integrated_dataset.csv termina con **155 filas** en vez de 154: la misma persona partida en dos, con métricas de red en una fila y score de éxito en otra.

Consecuencias. Una observación duplicada/incompleta en M3; author_success_scores.csv registra 149 “autores” con al menos un fantasma.

Solución (módulos creados 2026-07-07). code/lib_names.py y code/lib_names.R: correcciones explícitas (incl. nombres invertidos tipo “Dayyana, Gonzalez”), match normalizado sin tildes, resolución de apellido único (“Roa” → “Roa, Giovanna”), y clasificación de **no-personas** (iniciativas populares registradas como autor). Verificado sobre el snapshot completo: 70.043 menciones, 100% de las personas resuelven a los 154 canónicos; el QA 0a falla si aparece un string nuevo no resuelto. **Queda:** que los scripts del pipeline usen este módulo al reescribirse (elimina el bug Sepúlveda/155 filas por construcción).

P5 — Perfiles BCN incompletos [RESUELTO 2026-07-07]

Situación original. conventional-profiles.json tenía **147/154** perfiles. Los 7 ausentes (Botto, Castillo M.T., González D., Reyes M.R., Rivera M.M., Tepper, Zúñiga L.A.) recibían valores por defecto (edad 45, flags 0, afiliación “Desconocida”) en los scripts.

Diagnóstico (resuelto). match_names() en CPT/conventionals-bcn-webscrapping/fetch_convencionales.py exigía que el campo *nombre de pila completo* fuera substring contiguo del directorio BCN. La BCN registra un solo nombre de pila y a veces **el segundo** (“Ramona” Reyes, “Angélica” Tepper, “Arturo” Zúñiga), y en un caso con ortografía distinta (“Dayyana” González). **Fix aplicado 2026-07-06:** matching en tres niveles (campo completo → cualquier token exacto del nombre de pila → fuzzy difflib ≥ 0.85), verificado: 154/154 matcheados, **0 cambios de URL** en los 147 previos, re-scraping completo ejecutado. conventional-profiles.json tiene ahora **154 perfiles**; los 7 recuperados traen género, distrito y edad correctos.

Pendiente (auditoría manual de covariables).

1. **Afiliación “Desconocida” (33/154).** Incluye políticos de militancia pública y conocida (Chahin, Monckeberg, Larraín, Celis, Mayol...): es un fallo de extracción de la ficha BCN (la propiedad semántica `bcnbio:ofNamedPoliticalParty` no siempre está), no independencia real. Dado que `nodematch(afiliación)` es un término central de M1, **debe completarse a mano**.
2. **Falsos “Independiente”.** La heurística de respaldo de `process_profiles.py` (busca “Independiente” en la trayectoria textual) produce falsos positivos: p. ej. asignó “Independiente” a Arturo Zúñiga (militante UDI). La auditoría debe validar también los “Independiente” de figuras con militancia conocida.
3. **Faltantes enmascarados.** `es_mujer`, `es_abogado`, `grado_academico_nivel` y `experiencia_previa_institucional` no admiten NA: el default 0 significa “no detectado por la heurística de texto”, no “negativo confirmado” (p. ej. `es_mujer` se infiere de terminación en “-a” o palabras como “casada”). Riesgo directo sobre H1b (abogados, experiencia). Auditar al menos esos dos campos.
4. **Distrito “Desconocido” (9/154).** Aguilera, Bacián, Chinga, Galleguillos, Godoy, González L., Jiménez, Tirado, Vargas M. — todos **escaños reservados de pueblos originarios no mapuche**: no es dato faltante; recodificar como “Escaño reservado”.
5. **Edad (1/154).** Renato Garín sin fecha de nacimiento en BCN; completar a mano.

Auditoría dual-fuente ejecutada (2026-07-06). `code/0b-audit-profiles-dual-source.py` consulta `gemini-3.5-flash` (API Gemini con *search grounding*): para cada convencional extrae las características dos veces, de forma independiente — desde el texto BCN ya scrapeado y desde su artículo de Wikipedia en español — referidas al período de la Convención. Outputs en `data/raw/profile-audit/`: tabla de símbolos 154×8 (= coinciden, ≠ discrepan, B/W una sola fuente, ∅ ninguna), valores por fuente, y `discrepancias_pipeline.csv`. Resultados de la corrida v1 (lotes de 5): 154/154 auditados, ~124 con artículo de Wikipedia; **135 discrepancias** con el pipeline: afiliación 62 (resuelve las 33 “Desconocida” — Monckeberg→RN, Larraín→Evópoli, etc. — y detecta falsos “Independiente”: Zúñiga→UDI), grado académico 29, experiencia previa 24, distrito 17 (incluye los 9 escaños reservados), género 1, edad 1 (Garín: 35), abogado 1.

Cierre (2026-07-07). Tras la validación manual del usuario sobre las primeras ~36 discrepancias (registrada en `manual_validations.json`), se ejecutó la **corrida v2** (lotes de 6, grado académico en escala 0–3; carpeta `profiles-batches/`) y se automatizó la **imputación** con la regla del usuario: *BCN es ground truth; si BCN no informa, Wikipedia; si ninguna, valor base; las validaciones manuales siempre prevalecen*. Chequeo de consistencia v1 vs. v2 (`runs_consistency.csv`): 100% de acuerdo en género, fecha, distrito y experiencia; 99.6% abogado; 97.5% lista; 96.0% grado (mapeando escalas); 93.5% afiliación — los desacuerdos residuales quedan listados para inspección. Las 6 validaciones de grado hechas bajo la escala antigua (1 = magíster) se recodificaron a 2 en la escala nueva (ambas corridas corroboran magíster); los distritos de escaños reservados se estandarizaron a “Escaño reservado: <pueblo>”. Resultado vigente en `data/raw/conventional-profiles.json`: **154 perfiles** (incluye a Botto y los otros 6 recuperados), **0 afiliaciones “Desconocida”**, 0 edades faltantes, grado 0–3 = {0: 18, 1: 81, 2: 41, 3: 14}. Validaciones manuales en conflicto con la regla automática que se preservaron: Chahin→DC (BCN decía “Independiente”) y Arrau→Republicano (la v2-BCN leyó UDI). Nuevas correcciones futuras se agregan a `manual_validations.json` y se re-corre `--impute`.

P6 — Selección sobre la variable dependiente en M3 (ART-FALLIDO) [ABIERTO — decisión tomada]

Situación. La DV vigente promedia la similitud solo sobre los artículos **mapeados** al borrador final:

$$y_i = \frac{1}{|M_i|} \sum_{a \in M_i} \text{sim}(a), \quad M_i = \{a \in A_i : \text{final_status} \in \{\text{Idéntico}, \text{Similar}\}\}$$

Los artículos fallidos no entran ni al numerador ni al denominador. Consecuencias: (i) y_i mide retención *condicional a sobrevivir* — un delegado con 1/10 iniciativas sobrevivientes idénticas puntúa igual que uno con 10/10; (ii) los delegados cuyos artículos fallaron todos salen de la muestra (parte de la caída a $N = 141$): selección clásica sobre la DV.

Solución (decisión confirmada 2026-07-06). Con `final_status = ART-FALLIDO` disponible en las 7

comisiones, la DV principal pasa a incluir los fallidos con similitud 0:

$$y'_i = \frac{1}{|A_i|} \sum_{a \in A_i} \text{sim}(a) = \underbrace{\frac{|M_i|}{|A_i|}}_{\text{tasa de supervivencia } \hat{s}_i} \times \underbrace{\overline{\text{sim}}_{M_i}}_{\text{retención condicional } \bar{r}_i}$$

es decir, retención esperada por iniciativa presentada. La DV antigua queda como robustez; si la masa de ceros resulta grande, se agrega un modelo en dos partes ($\hat{s}_i$ y $\bar{r}_i$ por separado) como chequeo.

P7 — Mapeo génesis→final recalculado desde insumos legacy [ABIERTO — decisión tomada]

Situación. 04-build-article-mapping.py reconstruye el mapeo leyendo draft-after-indications-manual/ (legacy, solo C1/C3/C5) y filtrando final_status con matching de strings; produce 236 artículos mapeados.

Solución (decisión 2026-07-06). CPT/coincidencias_comisiones.csv — curada a mano en el PR #4, en UTF-8, con los 498 artículos del borrador final, su comisión de origen, estatus (identical/similar), y fuentes múltiples (primaria/secundaria/terciaria) — pasa a ser la **fuentes de verdad** del mapeo. El script 04 se reduce a un lector/validador de esa tabla; los textos finales se toman de los C{k}_BORRADOR_final.json.

P8 — Heterogeneidades residuales en dataverse-final [PARCIAL — la mayoría resuelta aguas arriba 2026-07-07]

Estado tras la revisión del usuario en CPT (paper-draft @ 5852519) y el QA del snapshot:

1. **[RESUELTO aguas arriba]** Títulos de capítulo de C1 eliminados (TRACK_full 230 → 202; typo "tite" desapareció con ellos); article_uid y final_status al 100% tras la armonización de ids (f8b9ddc); step normalizado a "Indicacion" en todos los niveles (3.205 reemplazos; C2 conserva sus etiquetas propias); nombres de archivo GENESIS unificados a C{k}_GENESIS_master.json; semántica de timestamp documentada en el codebook (MM-DD, año implícito 2022, sufijo -{bloque} = n-ésimo informe del día).
2. **[ABIERTO — CPT]** Esquema GENESIS aún heterogéneo (C1/C2/C3 sin article_uid; C4 sin article/sources; authors intermitente); asignado en CPT con la instrucción de heredar los uids de TRACK/crosswalk. El loader de este repo lo absorbe mientras tanto.
3. **[ABIERTO — loader]** Indicaciones sueltas (210): se mantiene la decisión — alimentan las ondas de M2 (205/210 con authors+timestamp), no entran a M1 ni a M3. Falta la aserción de no-duplicación contra history[] en el loader.
4. **[RESUELTO aguas arriba — ronda 2]** Timestamps sin fecha: los 66 top-level + 5 anidados quedaron documentados como undated en el codebook (49e394e); no se imputan (recuperarlos exigiría volver a los PDF de origen). En M2, los registros sin fecha se reportan y se excluyen de las ondas.

P9 — W y centralidades de M3 medidas sobre la red posterior al resultado [ABIERTO — decisión tomada]

Situación. La W del SDM y las covariables degree/betweenness se calculan sobre la red pooled acumulada final, que incluye lazos formados durante todo el proceso — en parte después de los eventos que determinaron la suerte de los artículos. Simultaneidad estructura ↔ resultado.

Solución (decisión 2026-07-06). Medir W y las centralidades sobre la **red génesis** (coherente con P2): la estructura precede al resultado. La red acumulada queda como robustez. Extensión futura (M4, no compromete el paper actual): modelo de supervivencia a nivel artículo-onda, con la posición de red de los autores en la red vigente en cada onda — los datos lo permiten (timestamps de indicaciones en las 7 comisiones, voting_result, final_status; el momento de muerte de un fallido se aproxima con su última aparición en el historial).

P10 — dynIRT sin errores estándar [ABIERTO — prioridad baja]

No existe `emIRT_bootstrap_output.rds`; `theta_se` queda NA en el pipeline (el script 02 lo tolera). Decidir si (i) bootstrap paramétrico del dynIRT, o (ii) reportar sensibilidad de M2 a la incertidumbre de θ de otro modo. No bloquea la actualización.

P11 — ERGMs por comisión sin convergencia plena [ABIERTO]

En la robustez vigente, los Valued ERGM de C3 y C5 no convergieron plenamente (muestras chicas a nivel de comisión). Con 7 comisiones el problema puede repetirse en las nuevas; plan: reintentar con los datos nuevos y, si persiste, reportar solo el pooled + los que converjan, documentándolo.

P12 — Sin exportación de figuras ni tablas [ABIERTO]

`results/figures/` y `results/tables/` están vacíos; las tablas del extended abstract están escritas a mano en el `.tex`. Riesgo de divergencia silenciosa entre resultados y paper (ya ocurrió: el abstract dice “max weight > 300” cuando el máximo real es 480; ver P13.3). Plan: cada script de modelo exporta sus tablas (CSV + LaTeX) y figuras a `results/`, y el `.tex` las incluye en vez de duplicarlas.

P13 — Errores y desactualizaciones en los documentos del paper [ABIERTO]

1. **Rótulos temáticos de comisiones equivocados.** `docs/extended-abstract.tex` (§Data) describe “C5: Fundamental Rights; C6: Environment”. Según la numeración oficial (verificada; §3.1), C5 es **Medio Ambiente** y C6 es **Sistemas de Justicia** (Derechos Fundamentales es C4, que no estaba en la muestra). La numeración de los archivos es consistente con la oficial; son los rótulos temáticos del texto (y del README) los que están corridos.
2. **“155 delegates” vs. 154** en pasajes del abstract y propuesta (154 es el n tras normalización de nombres; la Convención tuvo 155 escaños — precisar la distinción donde corresponda).
3. **Cifras a regenerar** tras la actualización: todas las tablas, el “max weight > 300” (real: 480), N de panel (2.926), N del SDM (141), artículos mapeados (236), y el párrafo “Ongoing work” sobre comisiones pendientes (desaparece).
4. **Cambio metodológico no documentado:** la propuesta original (`docs/research-proposal.tex`) prometía TERGM (M1) y SAOM/RSiena (M2); la implementación usa Valued ERGM y panel FE. Documentar la justificación (tamaño/estructura de los datos; identificación de selección vs. influencia vía FE + falsificación) en el README y en la próxima versión del paper.

P14 — Copias de insumos desincronizadas entre repos [RESUELTO 2026-07-07]

Regla instaurada: **este repo consume snapshots versionados de CPT; ningún script lee de CPT en runtime.** El snapshot `data/raw/dataverse-final/` (CPT paper-draft @ 5852519) incluye README de procedencia, codebook y `QA-report.txt`; se refresca copiando desde CPT y corriendo `code/0a-verify-dataverse-snapshot.py`. Los perfiles curados viven en `data/raw/conventional-profiles.json` (P5). Las carpetas `data/raw/commissions/` y `data/raw/network-visualization/` quedan como legacy de solo-lectura para comparación con los resultados pre-actualización.

P15 — C2 sin autores: no podía entrar a la red de co-patrocinio [RESUELTO aguas arriba 2026-07-07, ronda 2]

Situación original (QA 2026-07-07 a.m.). C2 no tenía `authors` en ninguna parte utilizable (0/312 GENESIS, 0/182 artículos TRACK_full); C4 tenía un hueco parcial (135/167, sin `sources` para el join).

Resolución (CPT paper-draft 55fae5d → 6fac4c4). `authors` poblado con la misma regla con que se construyó el resto del dataset — autores = firmantes de la(s) iniciativa(s) en `sources` (C2, 401 registros; regla validada 1.252/1.253 contra C3/C5/C6/C7) y vía `icc_id` (C4, 39 registros; validada 163/163). Verificado en el snapshot refrescado: C2 149/182 y C4 150/167 artículos con autores; **1.676 artículos con ≥ 2 autores-persona** para la red génesis, con las 7 comisiones aportando; las 75.616 menciones siguen resolviendo al

100% (los nuevos autores vienen en formato canónico). Residuo irrecuperable documentado en el codebook: 134/2.019 (65 populares/indígenas — patrocinio institucional, no de convencionales —, 45 de ICC ausentes del pool de PDF, 24 sin referencia de fuente).

Nota de alcance para M2. El `history[]` de C2 sigue delgado (33/54 entradas utilizables) y C2 no tiene indicaciones sueltas: C2 entra plenamente a M1 (génesis) y M3 (éxito), pero sus ondas en M2 aportarán poca variación intra-comisión — esperable y no bloqueante.

6. Decisiones de diseño confirmadas

Fecha	Decisión
2026-07-06	<code>coincidencias_comisiones.csv</code> (UTF-8) es la fuente de verdad del mapeo génesis→borrador final (P7).
2026-07-06	M1 = red génesis pura , 7 comisiones. Indicaciones solo en las ondas de M2. Génesis+indicaciones como robustez (P2).
2026-07-06	M3 : DV principal con <code>ART-FALLIDO = 0</code> ($y' = \hat{s} \cdot \bar{r}$); DV condicional antigua como robustez (P6). <i>W</i> y centralidades sobre la red génesis (P9).
2026-07-06	M2 : exposición acumulada desde T0 hasta $t - 1$ como especificación principal; robustez con decaimiento exponencial y con ventana solo-última-onda; sensibilidad estandarizando $\Delta\theta$ por días entre ondas.
2026-07-06	Indicaciones sueltas: entran a las ondas de M2 (timestamp+authors), no a M1 ni a M3; títulos se descartan (P8).
2026-07-06	Numeración oficial de comisiones confirmada; rótulos temáticos del paper a corregir (P13.1).
2026-07-06	Scraper BCN corregido y re-ejecutado: 154/154 perfiles (P5).
2026-07-06	Auditoría P5 vía <code>gemini-3.5-flash</code> (BCN + Wikipedia independientes, lotes de 5, situación al momento de la CC); símbolos <code>=/≠/B/W/∅</code> por celda; validación humana antes de regenerar covariables.
2026-07-06	Arreglos que corresponden al repo CPT registrados en <code>CPT-arreglos-pendientes.txt</code> (raíz); se abordarán en ese repositorio.
2026-07-07	Grado académico pasa a escala ordinal 0–3 (sin estudios universitarios terminados / educación superior terminada / magíster / doctorado) y entra a M1 como absdiff (distancia educativa).
2026-07-07	Imputación automatizada de covariables: BCN ground truth → Wikipedia → base; <code>manual_validations.json</code> siempre prevalece. <code>data/raw/conventional-profiles.json</code> es el archivo curado canónico (154).

Fecha	Decisión
2026-07-07	Snapshot dataverse-final ingerido (CPT paper-draft @ 5852519) con test de aceptación 0a; regla P14 instaurada. Infraestructura de Fase 0 creada: <code>paths.py/paths.R</code> , <code>lib_names.py/lib_names.R</code> .
2026-07-07	Las referencias a iniciativas populares en authors se clasifican como no-persona y quedan fuera de la red de co-patrocinio.
2026-07-07	Actualización con C1 y C3 a C7 → ronda 2 de CPT resolvió P15: las 7 comisiones entran a la actualización (snapshot @ 6fac4c4).
2026-07-07	Registros sin fecha (“undated”) y residuo de 134 sin autores: documentados, no imputados; se excluyen de las ondas / de la red según corresponda.

7. Plan de actualización

- **Fase 0 — Infraestructura: completada** (2026-07-07): snapshot **dataverse-final** versionado + QA de aceptación (0a-verify-dataverse-snapshot.py); perfiles curados 154; `paths.py/paths.R`; `lib_names.py/lib_names.R` con validación al 100%. (*P14 cerrado; P3 y P4 quedan en su mitad de recableado de scripts.*)
- **Fase 0b — Calidad de covariables: completada** (2026-07-07): auditoría dual-fuente v1+v2, validación manual, e imputación automática con capa de validaciones humanas; `data/raw/conventional-profiles.json` regenerado con 154 perfiles curados. (*P5 cerrado.*)
- **Fase 1 — Loader unificado:** lector GENESIS (2 esquemas), lector TRACK_full (clasificación artículo/indicación-suelta/título, dedup, timestamps), tests de conteos contra §3.1. (*Cierra P8.*)
- **Fase 2 — Redes:** red génesis pooled de las **7 comisiones** (P15 resuelto; 1.676 eventos de co-firma) para M1; ondas acumuladas por comisión para M2 con bins derivados de los timestamps observados; variantes de robustez. Decisión a tomar al construirla: unidad de co-firma por **artículo** (compatible con la versión anterior) vs. por **iniciativa** (dedupe vía `sources/icc_id`; una iniciativa multi-artículo cuenta una vez) — propuesta: artículo como principal, iniciativa como robustez. (*Cierra P1-red, P2.*)
- **Fase 3 — Modelos:** M1 ERGM (pooled + por comisión); M2 realineación emIRT + panel ampliado + robusteces de ventana; M3 con **coincidencias** + BORRADOR_final + DV nueva + W-génesis. (*Cierra P1, P6, P7, P9; revisita P11.*)
- **Fase 4 — Integración y paper:** `integrated_dataset` de exactamente 154 filas; suite de robustez; exportación automatizada a `results/`; actualización del extended abstract (cifras, rótulos, “ongoing work”) y README (métodos). (*Cierra P12, P13.*)

8. Registro de cambios de este documento

- **v1.4 (2026-07-07).** Ronda 2 de CPT ingerida (snapshot @ 6fac4c4): P15 resuelto (authors de C2 vía `sources`→firmantes y C4 vía `icc_id`; 1.676 artículos con ≥ 2 autores; residuo 134 documentado), timestamps *undated* documentados (P8.4). QA re-ejecutado: 75.616 menciones, 100% resueltas. Las 7 comisiones entran a la actualización; luz verde para reescribir el pipeline.
- **v1.3 (2026-07-07).** Fase 0 completada: snapshot **dataverse-final** ingerido (CPT **paper-draft @ 5852519**; TRACK_full 2.019, 210 indicaciones sueltas, uid/final_status 100%), test de aceptación 0a, módulos `paths` y `lib_names` (70.043 menciones de autor validadas al 100%, con filtro de iniciativas populares). P14 cerrado; P3/P4/P8 avanzados a parcial; **nuevo P15:** C2 sin **authors** (bloqueado en CPT). §3 reescrita con las cifras del snapshot.
- **v1.2 (2026-07-07).** P5 cerrado: corrida v2 de la auditoría (lotes de 6, grado 0–3, `profiles-batches/`), chequeo de consistencia v1 vs. v2, e imputación automatizada (BCN → Wikipedia → base, con

`manual_validations.json` prevaleciendo); `data/raw/conventional-profiles.json` regenerado (154 perfiles curados, 0 “Desconocida”). Decisión de modelo: `absdiff(grado académico 0--3)` se agrega a M1.

- **v1.1 (2026-07-06)**. P5: auditoría dual-fuente BCN+Wikipedia ejecutada con `gemini-3.5-flash` (154/154; 135 discrepancias con el pipeline; tablas en `data/raw/profile-audit/`). Nuevo `CPT-arreglos-pendientes.txt` en la raíz con los arreglos que corresponden al repositorio de datos (P8, higiene, documentación).
- **v1 (2026-07-06)**. Versión inicial: objetivos y marco teórico (§2), inventario de datos nuevos (§3), pipeline y resultados vigentes (§4), registro detallado de problemas P1–P14 (§5), decisiones confirmadas (§6) y plan por fases (§7). Incluye el fix del scraper BCN (P5) aplicado en esta fecha.