

Networked Influence in a Tabula Rasa Legislature — Reporte del estudio v1

Redes de co-patrocinio, dinámicas ideológicas y éxito político en la Convención Constitucional de Chile (2021–2022)

A. Olivera, J. Fábrega

July 6, 2026

Contents

1. Propósito de este documento	2
2. Objetivos del proyecto	2
2.1 Contexto: la Convención Constitucional como experimento natural	2
2.2 Preguntas de investigación	2
2.3 Marco teórico	3
2.4 Diseño: tres modelos	3
3. Datos	4
3.1 Fuentes primarias (estado objetivo, post-actualización)	4
3.2 Esquema de los datos de trazabilidad	5
3.3 Datos usados por la versión vigente (pre-actualización)	5
4. Pipeline y resultados vigentes	6
4.1 Scripts	6
4.2 Resultados vigentes (extended abstract, abril 2026)	6
5. Problemas identificados (registro detallado)	6
P1 — Cobertura incompleta de comisiones [ABIERTO — motivo central de la actualización]	6
P2 — Definición de lazo inconsistente entre comisiones [ABIERTO — decisión tomada]	7
P3 — Reproducibilidad rota: rutas hardcoded a carpetas legacy de otro repositorio [ABIERTO]	7
P4 — Normalización de nombres fragmentada (bug de las 155 filas) [ABIERTO]	7
P5 — Perfiles BCN incompletos [PARCIAL — scraper resuelto y auditoría dual-fuente ejecutada 2026-07-06; validación humana pendiente]	8
P6 — Selección sobre la variable dependiente en M3 (ART-FALLIDO) [ABIERTO — decisión tomada]	9
P7 — Mapeo génesis→final recalculado desde insumos legacy [ABIERTO — decisión tomada]	9
P8 — Heterogeneidades residuales en dataverse-final [ABIERTO]	9
P9 — <i>W</i> y centralidades de M3 medidas sobre la red posterior al resultado [ABIERTO — decisión tomada]	10
P10 — dynIRT sin errores estándar [ABIERTO — prioridad baja]	10
P11 — ERGMs por comisión sin convergencia plena [ABIERTO]	10
P12 — Sin exportación de figuras ni tablas [ABIERTO]	10
P13 — Errores y desactualizaciones en los documentos del paper [ABIERTO]	10
P14 — Copias de insumos desincronizadas entre repos [ABIERTO]	11

6. Decisiones de diseño confirmadas	11
7. Plan de actualización	11
8. Registro de cambios de este documento	12

1. Propósito de este documento

Este es el **reporte vivo** del proyecto: se actualiza a medida que el estudio avanza y registra, en un solo lugar, (i) los objetivos y el marco teórico, (ii) los datos y su procedencia exacta, (iii) el pipeline y los resultados vigentes, (iv) los **problemas identificados y su estado de resolución**, (v) las decisiones de diseño confirmadas, y (vi) el plan de trabajo. La versión v1 (julio 2026) documenta el estado del proyecto al momento de iniciar la **actualización de 5 a 7 comisiones** con los datos limpios de **dataverse-final** (PR #4 del repositorio de datos).

Convenciones: los problemas se etiquetan P1, P2, ... con estado **[ABIERTO]**, **[RESUELTO]** o **[PARCIAL]**. Las rutas relativas refieren a este repositorio; el repositorio de datos se abrevia CPT (= B - constitutional-proposal-tracking, en <https://github.com/aoliveram/constitutional-proposal-tracking>).

2. Objetivos del proyecto

2.1 Contexto: la Convención Constitucional como experimento natural

La Convención Constitucional chilena (julio 2021 – julio 2022) es un caso excepcionalmente limpio para estudiar la **génesis de redes políticas**. A diferencia de una legislatura ordinaria, donde las redes de colaboración observadas son el sedimento de décadas de carreras compartidas, disciplinas de partido y expectativas de reelección, la Convención partió de un cuasi-*tabula rasa* organizacional:

1. **Actores mutuamente desconocidos.** De los 155 escaños, una mayoría inédita correspondió a independientes y outsiders sin trayectoria parlamentaria, electos por listas ad hoc y escaños reservados para pueblos originarios (17). Gran parte de los delegados no se conocía entre sí ni compartía socialización partidaria.
2. **Sin jerarquías heredadas.** No existían comités con seniority, liderazgos de bancada consolidados ni “sombra del futuro” electoral común: el órgano se disolvía al entregar el texto.
3. **Reglas endógenas.** La Convención escribió su propio reglamento, incluyendo el mecanismo central que explota este estudio: toda **iniciativa convencional constituyente** requería el patrocinio de **al menos 8 y no más de 16 convencionales** (Reglamento General, art. 83). El piso obliga a formar coaliciones mínimas para participar del proceso; el techo impide que las firmas se diluyan en mega-bloques y convierte cada patrocinio en un recurso escaso y estratégico.
4. **Horizonte comprimido.** Todo el ciclo — formación de lazos, negociación, producción normativa y resultado (el borrador del 14-05-2022) — ocurre en ~10 meses y está íntegramente documentado, con autoría explícita en cada iniciativa e indicación.

El co-patrocinio es, por tanto, un **proxy observable, costoso y fechado de colaboración política**, y la Convención permite observar el ciclo completo: cómo se forman los lazos entre extraños (RQ1), qué hacen esos lazos con las posiciones de los actores (RQ2), y cómo la posición en la red se traduce en éxito sobre el texto final (RQ3).

2.2 Preguntas de investigación

- **RQ1 — Formación.** ¿Qué factores impulsan la formación de la red de co-patrocinio cuando no existen jerarquías previas? ¿Domina la homofilia clásica (afiliación, género) o aparecen estrategias de diversificación?
- **RQ2 — Influencia vs. selección.** ¿La exposición a los co-autores desplaza las posiciones ideológicas de los delegados (influencia social), o los delegados seleccionan co-autores ya afines (selección endógena)?

- **RQ3 — Éxito.** ¿Cómo predice la estructura de red el éxito político individual, operacionalizado como **retención léxica**: cuánto del texto que un delegado patrocinó sobrevive en el borrador constitucional final?

2.3 Marco teórico

(Apartado en construcción: esta sección fija el esqueleto argumental y se irá puliendo junto con la especificación final de los modelos.)

(a) Formación de lazos en legislaturas: homofilia y sus límites. La literatura de co-sponsorship en legislaturas consolidadas (Fowler 2006; Bratton & Rouse 2011; Kirkland 2011) documenta con robustez que los lazos siguen líneas de partido, región y género — homofilia en el sentido de McPherson, Smith-Lovin & Cook (2001). Pero esa literatura no puede separar cuánto de la homofilia observada es preferencia y cuánto es estructura heredada (comités, bancadas, historia). La Convención remueve la estructura heredada: lo que se observe en la formación temprana refleja preferencias y estrategias de actores en un campo casi vacío. **H1a (línea base):** persiste homofilia por afiliación política agrupada, el clivaje más visible incluso entre independientes.

(b) Gatekeeping estratégico: la homofilia negativa de los “dotados”. Para los actores con recursos escasos y transversalmente valiosos — pericia jurídica (abogados, en una asamblea cuyo producto es un texto legal) y experiencia institucional previa — la teoría de brokerage (Burt 1992; Padgett & Ansell 1993) predice lo contrario de la homofilia: maximizan influencia **dispersándose** entre coaliciones, ocupando agujeros estructurales en vez de agruparse entre sí. Se comportan como *gatekeepers* del conocimiento procedimental. **H1b:** abogados y delegados con experiencia institucional exhiben homofilia *negativa* (co-patrocinan menos entre sí de lo esperado), condicional en los demás términos del modelo.

(c) Influencia social vs. selección endógena. Que los conectados se parezcan ideológicamente admite dos mecanismos generativos: influencia (los lazos mueven las posiciones; Friedkin & Johnsen 1990) o selección (las posiciones crean los lazos). Distinguirlos es el problema clásico de la econometría de redes (Shalizi & Thomas 2011; en la tradición SAOM, Steglich, Snijders & Pearson 2010). Nuestra estrategia: panel con efectos fijos individuales (toda heterogeneidad estable del delegado queda absorbida) más un **test de falsificación** con exposición futura (*lead*): si el efecto contemporáneo fuera influencia causal, la exposición futura no debería “predecir” el cambio pasado. **H2:** en un cuerpo con posiciones ideológicas pre-formadas (los delegados llegan con identidades políticas adultas), domina la selección; el efecto de exposición desaparece bajo efectos fijos.

(d) El éxito legislativo como fenómeno colectivo. La efectividad legislativa suele tratarse como atributo individual (Volden & Wiseman 2014). Pero si la unidad de producción es la coalición firmante — y el reglamento fuerza que lo sea — el éxito debería *derramarse* por los lazos de co-autoría: mi retención léxica depende de la retención de aquellos con quienes escribo. Econométricamente eso es autocorrelación espacial en la variable de resultado sobre la topología de la red, y el marco natural son los modelos espaciales sobre redes (LeSage & Pace 2009). **H3:** la retención léxica exhibe dependencia de red fuerte; los modelos con rezago espacial (SAR/SDM) dominan al OLS, y el componente indirecto (spillover) de los efectos es sustantivo.

(e) Anclaje ideológico. Las posiciones ideológicas se estiman desde el comportamiento de votación nominal con un modelo dinámico de puntos ideales (dynIRT; Martin & Quinn 2002; implementación **emIRT** de Imai, Lo & Olmsted 2016), con prior de caminata aleatoria ($\omega^2 = 0.025$) y anclaje por dos delegados de posición pública inequívoca (Marinovic a la derecha, Baradit a la izquierda). Resultado: matriz $\Theta \in \mathbb{R}^{154 \times 91}$ (delegados $\times$ períodos de votación, 2021-07-13 a 2022-06-24).

2.4 Diseño: tres modelos

M1 — Formación (Valued ERGM). Red pooled de co-patrocinio con pesos $w_{ij} = n^\circ$ de documentos co-firmados. ERGM valuado con referencia Poisson:

$$P(W = w) \propto \exp\{\theta^\top g(w)\}, \quad g = (\text{sum}, \text{nodematch}_{\text{afiliación}}, \text{abogado}, \text{experiencia}, \text{género}, \text{absdiff}_{\text{edad}}, \text{nodecov}_{\text{edad}})$$

Los términos **nodematch** capturan homofilia (H1a) y su reverso (H1b).

M2 — Dinámica ideológica (panel FE). Sobre ondas temporales por comisión:

$$\Delta\theta_{i,t} = \alpha_i + \beta_1\theta_{i,t-1} + \beta_3 \text{NetExp}_{i,t-1} + \varepsilon_{it}, \quad \text{NetExp}_{i,t-1} = \frac{\sum_{j \neq i} w_{ij,t-1} \theta_{j,t-1}}{\sum_{j \neq i} w_{ij,t-1}}$$

con $w_{ij,t-1}$ = co-firmas acumuladas hasta la onda $t-1$. Comparación OLS agrupado vs. efectos fijos (within) vs. aleatorios (Hausman), errores agrupados por delegado, y falsificación con *lead*.

M3 — Éxito (Spatial Durbin Model). Con y_i = retención léxica media del delegado (similitud coseno TF-IDF génesis→final; robustez con Sentence-BERT) y W = matriz de co-autoría row-normalizada:

$$y = \rho W y + X\beta + W X \gamma + \varepsilon$$

Se compara OLS/SAR/SEM/SDM (AIC, Moran's I) y se descomponen efectos directos/indirectos/totales.

3. Datos

3.1 Fuentes primarias (estado objetivo, post-actualización)

Fuente	Ubicación	Contenido	N
Iniciativas génesis	CPT/comision-{1..7}/data/verse-final/0{k}_GENESIS_master[_merged].json	Iniciativas finales/0{k}_GENESIS_master[_merged].json aprobadas en general, con authors	1.892
Trazabilidad completa	.../C{k}_TRACK_full.json	Todos los artículos (incl. fallidos) con history[] de indicaciones fechadas y final_status	2.047
Trazabilidad filtrada	.../C{k}_TRACK_articles.json	Sólo artículos presentes en el borrador final	478
Borrador final	.../C{k}_BORRADOR_final.json	Artículos del borrador del 14-05-2022, por comisión	498
Mapeo maestro	CPT/coincidencias_comisionados.txt (UTF-8)	Artículos finales → fuente(s) por comisión, estatus identical/similar, fuentes secundarias/terciarias	498
Nombres canónicos	data/raw/convention_members.json	Referencia oficial “Apellido, Nombre”	154
Perfiles BCN	CPT/conventionals-bcn-w/overlapping/conventional-profiles.json	Observables de afiliación, distrito, abogado, edad, grado, experiencia	154
Puntos ideales	data/raw/emirt/	Salidas dynIRT: Θ 154×91, metadata, posiciones resumen	154×91

Desglose por comisión de los **dataverse-final** (conteo de registros):

Comisión	Nombre oficial (corto)	GENESIS	BORRADOR	TRACK_articles	TRACK_full
C1	Sistema Político	96	100	131	230
C2	Principios Con- stitucionales	312	41	24	182
C3	Forma de Estado	222	96	72	234
C4	Derechos Fundamentales	167	58	58	175
C5	Medio Ambiente	464	43	36	484
C6	Sistemas de Justicia	440	119	117	491
C7	Sistemas de Conocimientos	191	41	40	251
Total		1.892	498	478	2.047

Nombres oficiales completos de las comisiones (verificados 2026-07-06 contra el registro oficial `cconstituyente.cl`, Wikipedia y UNESCO; ver P13):

1. Sistema Político, Gobierno, Poder Legislativo y Sistema Electoral
2. Principios Constitucionales, Democracia, Nacionalidad y Ciudadanía
3. Forma de Estado, Ordenamiento, Autonomía, Descentralización, Equidad, Justicia Territorial, Gobiernos Locales y Organización Fiscal
4. Derechos Fundamentales
5. Medio Ambiente, Derechos de la Naturaleza, Bienes Naturales Comunes y Modelo Económico
6. Sistemas de Justicia, Órganos Autónomos de Control y Reforma Constitucional
7. Sistemas de Conocimientos, Culturas, Ciencia, Tecnología, Artes y Patrimonios

3.2 Esquema de los datos de trazabilidad

Cada registro de artículo en `TRACK_full` contiene: `article_uid` (identificador único, guiones bajos), `article`, `timestamp` (formato MM-DD), `text`, `sources` (iniciativas de origen), `authors` (array "Apellido, Nombre"), `final_status` ("Idéntico a N.- ..." / "Similar a N.- ..." / "ART-FALLIDO"), y `history[]`. Cada entrada de `history[]` es una **indicación** fechada: `timestamp`, `step`, `number`, `authors`, `action` (ADD/DELETE/...), `target_scope`, `content`, `content_to_remove`, `placement_instructions`, `content_snapshot`.

Dos hechos estructurales importan para el pipeline (detalle en P8):

- El esquema del GENESIS tiene **dos variantes** (C1/C2/C3/C6 vs. C4/C5/C7).
- Todos los `TRACK_full` salvo C2 contienen “**indicaciones sueltas**”: registros de indicación al nivel superior, no anidados en `history[]` (C1: 103; C3: 12; C4: 8; C5: 20; C6: 44; C7: 23). C1 contiene además 28 registros de títulos de capítulo. Regla mecánica de clasificación: `titleuid` presente → título; `action` presente al nivel superior → indicación suelta; en otro caso → artículo.

3.3 Datos usados por la versión vigente (pre-actualización)

La versión reflejada en el extended abstract (abril 2026) usa insumos **anteriores** al PR #4 de limpieza, copiados en `data/raw/commissions/` (5 archivos: C1, C3, C5, C6, C7, enriquecidos a mano) y redes pre-construidas en `data/raw/network-visualization/`. Cifras vigentes: red pooled de **7.162 aristas**, **154 nodos**, **peso total 202.765**, **peso máximo 480**; ondas dinámicas solo para C1 (5), C3 (8) y C5 (6); mapeo génesis→final de **236 artículos** (125 idénticos + 111 similares; C1: 131, C3: 71, C5: 34); panel de **2.926** observaciones delegado-período; SDM sobre **141** casos completos.

4. Pipeline y resultados vigentes

4.1 Scripts

#	Script	Rol	Outputs
00	code/00-build_dynamic_networks.py	Redes de co-autoría (pooled + ondas C1/C3/C5)	pooled_cumulative_network.csv, {C}_dynamic_networks.json
01	code/01-model-valued-ergm	M1: Valued ERGM Poisson + centralidades	ergm_pooled_results.rds, network_metrics.csv
02	code/02-extract-emirt-temporal	Abstracción temporal $\Theta \leftrightarrow$ ondas de comisión	emirt_*.csv
03	code/03-model-network-influence	M2: Exposición de red + panel FE/RE/OLS	network_exposure_panel.csv, panel_regression_results.rds
04	code/04-build-article-mapping	M3: Mapeo de artículos comisión $\rightarrow$ borrador final	article_mapping_unified.{json,csv}
05	code/05-nlp-text-similarity	Retención léxica TF-IDF + SBERT	article_similarity_scores.csv, author_success_scores.csv
06	code/06-build-integrated-dataset	Integración de datos $\rightarrow$ ito+red+ideología+perfiles	integrated_dataset.{csv,json}
07	code/07-model-spatial-duration	M3: Moran, OLS/SAR/SEM/SDM, impactos	sdm_results.rds, sdm_impacts.csv
08	code/08-robustness-checks	Robustez de M1-M3	robustness_results.rds

4.2 Resultados vigentes (extended abstract, abril 2026)

- **M1.** `nodematch`(afiliación) = +0.41; `nodematch`(abogado) = -0.09; `nodematch`(experiencia) = -0.12; `nodematch`(mujer) = +0.08; `nodecov`(edad) = -0.024. Lectura: homofilia positiva de afiliación y género; **homofilia negativa** de abogados y experimentados (gatekeeping estratégico, H1b confirmada).
- **M2.** OLS agrupado: $\hat{\beta}_3 = +0.033$ ($p < 0.001$); efectos fijos: $\hat{\beta}_3 = +0.0004$ ($p = 0.91$); Hausman $\chi^2 = 784.96$ ($p < 0.001$) $\rightarrow$ FE. Falsificación con *lead* significativa ($p < 0.001$) $\rightarrow$ **selección, no influencia** (H2 confirmada).
- **M3.** Moran's $I = 0.155$ ($p < 10^{-6}$). AIC: OLS -338.5 < SEM -354.8 ($\lambda = 0.81$) < SAR -355.3 ($\rho = 0.89$) < **SDM** -383.4 ($\hat{\rho} = 0.997$). En OLS: `theta_mean` +0.012 ($p = 0.008$), `theta_sd` -0.103 ($p = 0.015$), `ego_heterophily` -0.063 ($p = 0.027$); centralidades n.s. Validación de medida: artículos “idénticos” puntúan 0.979 en TF-IDF. Robustez: SBERT preserva signos; con W binaria ρ cae a 0.374 manteniendo significancias clave (H3 confirmada).

5. Problemas identificados (registro detallado)

Esta sección es el inventario completo de defectos, deudas y decisiones pendientes detectados en la auditoría de julio 2026 (previa a la actualización). Es la lista de control contra la cual se ejecutará el plan de la §7.

P1 — Cobertura incompleta de comisiones [ABIERTO — motivo central de la actualización]

Situación. La versión vigente usa 5 de las 7 comisiones en M1 (C1, C3, C5, C6, C7; C2 y C4 ausentes del repo) y solo **3** en M2 y M3 (C1, C3, C5), porque los archivos antiguos de C6/C7 no tienen `final_status` ni ondas temporales. El propio abstract lo declara como limitación (“Ongoing work”).

Consecuencias. (i) La red pooled subestima lazos formados vía C2/C4 — con 312 y 167 iniciativas génesis, no son comisiones menores; C4 (Derechos Fundamentales) fue además la comisión políticamente más cargada. (ii) El mapeo de éxito cubre 236 de 498 artículos finales (47%): la DV de M3 ignora más de la mitad del borrador. (iii) El panel de M2 descarta la dinámica de 4 comisiones.

Solución. Migrar todo el pipeline a los `dataverse-final` de las 7 comisiones (PR #4 de CPT, mergeado): GENESIS para la red de co-patrocinio, TRACK_full para ondas e indicaciones, `coincidencias_comisiones.csv` + BORRADOR_final para el éxito.

P2 — Definición de lazo inconsistente entre comisiones [ABIERTO — decisión tomada]

Situación. En `code/00-build_dynamic_networks.py`, la red pooled suma la **última onda acumulada** de C1/C3/C5 (= génesis + **todas las indicaciones**, líneas 175–178) pero solo el génesis de C6/C7 (líneas 194–204). La red que estima M1 — y que M3 usa como *W* y para las centralidades — mezcla, por tanto, dos definiciones de lazo según la comisión.

Consecuencias. Los pesos no son comparables entre comisiones (C5 aporta 4.968 aristas acumuladas vs. C7 solo génesis); los coeficientes del ERGM confunden formación primaria con colaboración posterior.

Solución (decisión 2026-07-06). M1 usará exclusivamente la red **génesis** de las 7 comisiones: modela la *formación primaria* de lazos entre desconocidos, y el co-patrocinio de iniciativas es el acto fundacional (además, con umbral reglamentario 8–16 firmas, es un compromiso costoso y acotado). Las indicaciones entran solo a las **ondas acumuladas** de M2 (colaboración posterior, condicionada por la red ya formada). Para M3, ver P9. Robustez: red génesis+indicaciones como variante.

P3 — Reproducibilidad rota: rutas hardcodedas a carpetas legacy de otro repositorio [ABIERTO]

Situación. Los scripts 02–05 leen desde rutas absolutas del repo CPT, y además desde carpetas **legacy previas a la limpieza**: 02-extract-emirt-temporal.R:10 (`emIRT-analysis/`, escribe a `playground/research-proposal-implementation/data`), 03-model-network-influence.R:30–32 (`conventionals-bcn-webscrapping/`, `network-visualization/`), 04-build-article-mapping.py:15–22 (`comision-N/draft-after-indications-manual/`, `proposals/draft_final_text.json`), 05-nlp-text-similarity.py:2. El archivo `draft_final_text.json` ni siquiera existe en este repositorio. Los scripts 00, 01, 06, 07, 08 sí leen de `data/` local.

Consecuencias. El pipeline no corre de extremo a extremo desde este repo; los outputs commiteados en `data/processed/` no son regenerables por terceros; y los insumos legacy quedaron desactualizados respecto de `dataverse-final`.

Solución. Copiar los `dataverse-final` a `data/raw/dataverse-final/comision-{1..7}/` + un módulo único de configuración de rutas (`code/config`), del que todos los scripts derivan sus paths. Ningún script vuelve a referenciar CPT.

P4 — Normalización de nombres fragmentada (bug de las 155 filas) [ABIERTO]

Situación. El mapa NAME_CORRECTIONS (5 correcciones: Muñoz/Sepúlveda×2/Vargas-typo/Chinga) vive solo en `code/00-build_dynamic_networks.py`:35–41. El pipeline de éxito (04→05→06) corre sin esa normalización, así que "Sepúlveda, Barbara" (con tilde, desde los archivos de comisión) no cruza con "Sepulveda, Barbara" (canónico) y `integrated_dataset.csv` termina con **155 filas** en vez de 154: la misma persona partida en dos, con métricas de red en una fila y score de éxito en otra.

Consecuencias. Una observación duplicada/incompleta en M3; `author_success_scores.csv` registra 149 “autores” con al menos un fantasma.

Solución. Módulo compartido de normalización (Python + R) que (i) aplique correcciones, (ii) **valide todo autor contra los 154 canónicos** de `data/raw/convention_members.json`, y (iii) emita reporte de

no-matcheados en cada corrida. Con los datos nuevos (autores ya estandarizados por el PR #4) el mapa de correcciones debería encogerse, pero la validación queda como invariante del pipeline.

P5 — Perfiles BCN incompletos [PARCIAL — scraper resuelto y auditoría dual-fuente ejecutada 2026-07-06; validación humana pendiente]

Situación original. `conventional-profiles.json` tenía **147/154** perfiles. Los 7 ausentes (Botto, Castillo M.T., González D., Reyes M.R., Rivera M.M., Tepper, Zúñiga L.A.) recibían valores por defecto (edad 45, flags 0, afiliación “Desconocida”) en los scripts.

Diagnóstico (resuelto). `match_names()` en `CPT/conventionals-bcn-webscrapping/fetch_convencionales.py` exigía que el campo *nombre de pila completo* fuera substring contiguo del directorio BCN. La BCN registra un solo nombre de pila y a veces **el segundo** (“Ramona” Reyes, “Angélica” Tepper, “Arturo” Zúñiga), y en un caso con ortografía distinta (“Dayyana” González). **Fix aplicado 2026-07-06:** matching en tres niveles (campo completo → cualquier token exacto del nombre de pila → fuzzy `diffliib` ≥ 0.85), verificado: 154/154 matcheados, **0 cambios de URL** en los 147 previos, re-scraping completo ejecutado. `conventional-profiles.json` tiene ahora **154 perfiles**; los 7 recuperados traen género, distrito y edad correctos.

Pendiente (auditoría manual de covariables).

1. **Afiliación “Desconocida” (33/154).** Incluye políticos de militancia pública y conocida (Chahin, Monckeberg, Larraín, Celis, Mayol...): es un fallo de extracción de la ficha BCN (la propiedad semántica `bcnbio:ofNamedPoliticalParty` no siempre está), no independencia real. Dado que `nodematch(afiliación)` es un término central de M1, **debe completarse a mano**.
2. **Falsos “Independiente”.** La heurística de respaldo de `process_profiles.py` (busca “Independiente” en la trayectoria textual) produce falsos positivos: p. ej. asignó “Independiente” a Arturo Zúñiga (militante UDI). La auditoría debe validar también los “Independiente” de figuras con militancia conocida.
3. **Faltantes enmascarados.** `es_mujer`, `es_abogado`, `grado_academico_nivel` y `experiencia_previa_institucional` no admiten NA: el default 0 significa “no detectado por la heurística de texto”, no “negativo confirmado” (p. ej. `es_mujer` se infiere de terminación en “-a” o palabras como “casada”). Riesgo directo sobre H1b (abogados, experiencia). Auditar al menos esos dos campos.
4. **Distrito “Desconocido” (9/154).** Aguilera, Bacián, Chinga, Galleguillos, Godoy, González L., Jiménez, Tirado, Vargas M. — todos **escaños reservados de pueblos originarios no mapuche**: no es dato faltante; recodificar como “Escaño reservado”.
5. **Edad (1/154).** Renato Garín sin fecha de nacimiento en BCN; completar a mano.

Auditoría dual-fuente ejecutada (2026-07-06). `code/0b-audit-profiles-dual-source.py` consulta `gemini-3.5-flash` (API Gemini con *search grounding*) en lotes de 5 convencionales: para cada uno extrae las características dos veces, de forma independiente — desde el texto BCN ya scrapeado y desde su artículo de Wikipedia en español — referidas al período de la Convención. Outputs en `data/raw/profile-audit/`: tabla de símbolos 154×8 (= coinciden, ≠ discrepan, B/W una sola fuente, ∅ ninguna), valores por fuente, y `discrepancias_pipeline.csv`. Resultados: 154/154 auditados, ~124 con artículo de Wikipedia; entre fuentes duales el acuerdo es alto (género 124/124) con **34 conflictos** ≠ a revisar (afiliación 12, fecha de nacimiento 8, grado 6, abogado 4, experiencia 2, distrito 1, lista 1); contra el pipeline hay **135 discrepancias**: afiliación 62 (resuelve las 33 “Desconocida” — Monckeberg→RN, Larraín→Evópoli, etc. — y detecta falsos “Independiente”: Zúñiga→UDI), grado académico 29, experiencia previa 24, distrito 17 (incluye los 9 escaños reservados), género 1, edad 1 (Garín: 35), abogado 1. **Queda pendiente la validación humana** de `discrepancias_pipeline.csv`, con foco en los 12 conflictos de afiliación donde BCN y Wikipedia contradicen (p. ej. Chahin: BCN “Independiente” vs. Wikipedia “Demócrata Cristiano”); recién entonces se regeneran las covariables.

P6 — Selección sobre la variable dependiente en M3 (ART-FALLIDO) [ABIERTO — decisión tomada]

Situación. La DV vigente promedia la similitud solo sobre los artículos **mapeados** al borrador final:

$$y_i = \frac{1}{|M_i|} \sum_{a \in M_i} \text{sim}(a), \quad M_i = \{a \in A_i : \text{final_status} \in \{\text{Idéntico}, \text{Similar}\}\}$$

Los artículos fallidos no entran ni al numerador ni al denominador. Consecuencias: (i) y_i mide retención *condicional a sobrevivir* — un delegado con 1/10 iniciativas sobrevivientes idénticas puntúa igual que uno con 10/10; (ii) los delegados cuyos artículos fallaron todos salen de la muestra (parte de la caída a $N = 141$): selección clásica sobre la DV.

Solución (decisión confirmada 2026-07-06). Con `final_status = ART-FALLIDO` disponible en las 7 comisiones, la DV principal pasa a incluir los fallidos con similitud 0:

$$y'_i = \frac{1}{|A_i|} \sum_{a \in A_i} \text{sim}(a) = \underbrace{\frac{|M_i|}{|A_i|}}_{\text{tasa de supervivencia } \hat{s}_i} \times \underbrace{\overline{\text{sim}}_{M_i}}_{\text{retención condicional } \bar{r}_i}$$

es decir, retención esperada por iniciativa presentada. La DV antigua queda como robustez; si la masa de ceros resulta grande, se agrega un modelo en dos partes ($\hat{s}_i$ y $\bar{r}_i$ por separado) como chequeo.

P7 — Mapeo génesis→final recalculado desde insumos legacy [ABIERTO — decisión tomada]

Situación. `04-build-article-mapping.py` reconstruye el mapeo leyendo `draft-after-indications-manual/` (legacy, solo C1/C3/C5) y filtrando `final_status` con matching de strings; produce 236 artículos mapeados.

Solución (decisión 2026-07-06). `CPT/coincidencias_comisiones.csv` — curada a mano en el PR #4, en UTF-8, con los **498** artículos del borrador final, su comisión de origen, estatus (`identical/similar`), y fuentes múltiples (primaria/secundaria/terciaria) — pasa a ser la **fuentes de verdad** del mapeo. El script 04 se reduce a un lector/validador de esa tabla; los textos finales se toman de los `C{k}_BORRADOR_final.json`.

P8 — Heterogeneidades residuales en `dataverse-final` [ABIERTO]

Defectos de forma de los datos limpios que el loader debe absorber (ninguno requiere re-limpiar aguas arriba):

1. **GENESIS con dos esquemas y dos nombres de archivo.** C1/C2/C3/C6: campos `article/text/sources[/authors]`, archivo `*_master.json` (C2, C3, C6) o `*_master_merged.json` (C1). C4/C5/C7: campos `voting_result/authors/text/icc_id/article_uid`, archivo `*_master_merged.json`. El loader unifica a un esquema interno único.
2. **Indicaciones sueltas al nivel superior** en todos los `TRACK_full` salvo C2 (conteos en §3.2). Regla de clasificación: `titleuid` → título (descartar; solo C1, 28 registros); `action` al nivel superior → indicación suelta; resto → artículo. Las sueltas **no tienen sources** y su uid codifica el artículo destino de forma poco fiable (capítulos placeholder `CH*`): no se intentará anclarlas a artículos. Sí aportan lazos a las ondas de M2 (tienen `timestamp` y `authors`). No entran a la red génesis de M1 ni al éxito de M3 (que usa `coincidencias`).
3. **Riesgo de doble conteo.** Verificar programáticamente (hash de `authors+timestamp+content`) que ninguna indicación suelta duplique una entrada de `history[]`; en las inspecciones manuales no hubo solape, pero debe quedar como aserción del loader.
4. **Tipos y variantes menores.** Un registro con clave `"tite"` en C1; `step` = "Indicacion" (sin tilde, C1) vs. "Indicación" (C3/C6). No usar `step` como discriminador.
5. **Timestamps irregulares.** Formato `MM-DD` sin año, con variantes como `"04-01-2"` (sufijo de segunda sesión). Regla de parseo: prefijo `MM-DD` (matching por `startswith` contra los bins, como ya hace el script 00); año implícito 2022 para las ondas de indicaciones (la Convención sesionó jul-2021 → jul-2022 y todos los informes de comisión son de 2022). Definir los bins de ondas por comisión a partir

de los timestamps observados en `TRACK_full` (hoy solo existen para C1/C3/C5, hardcodedos en `00-build_dynamic_networks.py:44-48`).

P9 — W y centralidades de M3 medidas sobre la red posterior al resultado [ABIERTO — decisión tomada]

Situación. La W del SDM y las covariables `degree/betweenness` se calculan sobre la red pooled acumulada final, que incluye lazos formados durante todo el proceso — en parte *después* de los eventos que determinaron la suerte de los artículos. Simultaneidad estructura $\leftrightarrow$ resultado.

Solución (decisión 2026-07-06). Medir W y las centralidades sobre la **red génesis** (coherente con P2): la estructura precede al resultado. La red acumulada queda como robustez. Extensión futura (M4, no compromete el paper actual): modelo de supervivencia a nivel artículo-onda, con la posición de red de los autores en la red vigente en cada onda — los datos lo permiten (timestamps de indicaciones en las 7 comisiones, `voting_result`, `final_status`; el momento de muerte de un fallido se aproxima con su última aparición en el historial).

P10 — dynIRT sin errores estándar [ABIERTO — prioridad baja]

No existe `emIRT_bootstrap_output.rds`; `theta_se` queda NA en el pipeline (el script 02 lo tolera). Decidir si (i) bootstrap paramétrico del dynIRT, o (ii) reportar sensibilidad de M2 a la incertidumbre de θ de otro modo. No bloquea la actualización.

P11 — ERGMs por comisión sin convergencia plena [ABIERTO]

En la robustez vigente, los Valued ERGM de C3 y C5 no convergieron plenamente (muestras chicas a nivel de comisión). Con 7 comisiones el problema puede repetirse en las nuevas; plan: reintentar con los datos nuevos y, si persiste, reportar solo el pooled + los que converjan, documentándolo.

P12 — Sin exportación de figuras ni tablas [ABIERTO]

`results/figures/` y `results/tables/` están vacíos; las tablas del extended abstract están escritas a mano en el `.tex`. Riesgo de divergencia silenciosa entre resultados y paper (ya ocurrió: el abstract dice “max weight > 300” cuando el máximo real es 480; ver P13.3). Plan: cada script de modelo exporta sus tablas (CSV + LaTeX) y figuras a `results/`, y el `.tex` las incluye en vez de duplicarlas.

P13 — Errores y desactualizaciones en los documentos del paper [ABIERTO]

1. **Rótulos temáticos de comisiones equivocados.** `docs/extended-abstract.tex` (§Data) describe “C5: Fundamental Rights; C6: Environment”. Según la numeración oficial (verificada; §3.1), C5 es **Medio Ambiente** y C6 es **Sistemas de Justicia** (Derechos Fundamentales es C4, que no estaba en la muestra). La numeración de los archivos es consistente con la oficial; son los rótulos temáticos del texto (y del README) los que están corridos.
2. **“155 delegates” vs. 154** en pasajes del abstract y propuesta (154 es el n tras normalización de nombres; la Convención tuvo 155 escaños — precisar la distinción donde corresponda).
3. **Cifras a regenerar** tras la actualización: todas las tablas, el “max weight > 300” (real: 480), N de panel (2.926), N del SDM (141), artículos mapeados (236), y el párrafo “Ongoing work” sobre comisiones pendientes (desaparece).
4. **Cambio metodológico no documentado:** la propuesta original (`docs/research-proposal.tex`) prometía TERGM (M1) y SAOM/RSiena (M2); la implementación usa Valued ERGM y panel FE. Documentar la justificación (tamaño/estructura de los datos; identificación de selección vs. influencia vía FE + falsificación) en el README y en la próxima versión del paper.

P14 — Copias de insumos desincronizadas entre repos [ABIERTO]

`data/raw/conventional-profiles.json` (este repo) es una copia de la salida del scraper en CPT, hoy desactualizada (147 vs. 154 tras el fix de P5); `data/raw/commissions/` y `data/raw/network-visualization/` son copias de insumos legacy. Al ejecutar la Fase 0 (§7), las copias se reemplazan por los `dataverse-final` + perfiles regenerados, y se define una regla única: **este repo consume snapshots versionados de CPT; ningún script lee de CPT en runtime** (cierra también P3).

6. Decisiones de diseño confirmadas

Fecha	Decisión
2026-07-06	<code>coincidencias_comisiones.csv</code> (UTF-8) es la fuente de verdad del mapeo génesis→borrador final (P7).
2026-07-06	M1 = red génesis pura , 7 comisiones. Indicaciones solo en las ondas de M2. Génesis+indicaciones como robustez (P2).
2026-07-06	M3 : DV principal con ART-FALLIDO = 0 ($y' = \hat{s} \cdot \bar{r}$); DV condicional antigua como robustez (P6). <i>W</i> y centralidades sobre la red génesis (P9).
2026-07-06	M2 : exposición acumulada desde T0 hasta $t - 1$ como especificación principal; robustez con decaimiento exponencial y con ventana solo-última-onda; sensibilidad estandarizando $\Delta\theta$ por días entre ondas.
2026-07-06	Indicaciones sueltas: entran a las ondas de M2 (timestamp+authors), no a M1 ni a M3; títulos se descartan (P8).
2026-07-06	Numeración oficial de comisiones confirmada; rótulos temáticos del paper a corregir (P13.1).
2026-07-06	Scraper BCN corregido y re-ejecutado: 154/154 perfiles (P5).
2026-07-06	Auditoría P5 vía <code>gemini-3.5-flash</code> (BCN + Wikipedia independientes, lotes de 5, situación al momento de la CC); símbolos <code>=/≠/B/W/∅</code> por celda; validación humana antes de regenerar covariables.
2026-07-06	Arreglos que corresponden al repo CPT registrados en <code>CPT-arreglos-pendientes.txt</code> (raíz); se abordarán en ese repositorio.

7. Plan de actualización

- **Fase 0 — Infraestructura** (*branch dedicado*): copiar `dataverse-final` a `data/raw/dataverse-final/`; snapshot de perfiles 154; módulo de configuración de rutas; módulo compartido de normalización/validación de nombres. (*Cierra P3, P4, P14.*)
- **Fase 0b — Calidad de covariables**: ~~planilla de auditoría pre-llenada~~ → **hecho** vía auditoría dual-fuente (`data/raw/profile-audit/`); queda la validación humana de las 135 discrepancias (foco: 12 conflictos $\neq$ de afiliación) y la regeneración de covariables (incl. recodificación “Esaño reservado”). (*Cierra P5.*)
- **Fase 1 — Loader unificado**: lector GENESIS (2 esquemas), lector TRACK_full (clasificación artículo/indicación-suelta/título, dedup, timestamps), tests de conteos contra §3.1. (*Cierra P8.*)

- **Fase 2 — Redes:** red génesis pooled 7 comisiones (M1); ondas acumuladas por comisión $\times 7$ (M2); variantes de robustez. (*Cierra P1-red, P2.*)
- **Fase 3 — Modelos:** M1 ERGM (pooled + por comisión); M2 realineación emIRT + panel ampliado + robusteces de ventana; M3 con `coincidencias` + `BORRADOR_final` + DV nueva + *W*-génesis. (*Cierra P1, P6, P7, P9; revisita P11.*)
- **Fase 4 — Integración y paper:** `integrated_dataset` de exactamente 154 filas; suite de robustez; exportación automatizada a `results/`; actualización del extended abstract (cifras, rótulos, “ongoing work”) y README (métodos). (*Cierra P12, P13.*)

8. Registro de cambios de este documento

- **v1.1 (2026-07-06).** P5: auditoría dual-fuente BCN+Wikipedia ejecutada con `gemini-3.5-flash` (154/154; 135 discrepancias con el pipeline; tablas en `data/raw/profile-audit/`). Nuevo `CPT-arreglos-pendientes.txt` en la raíz con los arreglos que corresponden al repositorio de datos (P8, higiene, documentación).
- **v1 (2026-07-06).** Versión inicial: objetivos y marco teórico (§2), inventario de datos nuevos (§3), pipeline y resultados vigentes (§4), registro detallado de problemas P1–P14 (§5), decisiones confirmadas (§6) y plan por fases (§7). Incluye el fix del scraper BCN (P5) aplicado en esta fecha.