

Networked Influence in a Tabula Rasa Legislature — Reporte del estudio

Redes de co-patrocinio, dinámicas ideológicas y éxito político en la Convención Constitucional de Chile (2021–2022)

A. Olivera, J. Fábrega

July 8, 2026

Contents

1. Propósito de este documento	2
2. Objetivos del proyecto	2
2.1 Contexto: la Convención Constitucional como experimento natural	2
2.2 Preguntas de investigación	3
2.3 Marco teórico	3
2.4 Diseño: tres modelos	4
3. Datos	4
3.1 Fuentes primarias (estado objetivo, post-actualización)	4
3.2 Esquema de los datos de trazabilidad	6
3.3 Datos usados por la versión vigente (pre-actualización)	6
3.4 Regla de asignación de covariables de perfil	7
4. Pipeline y resultados	7
4.1 Scripts	7
4.2 Resultados de la versión anterior (extended abstract, abril 2026 — 5 comisiones, red mixta, perfiles heurísticos)	8
4.3 Resultados actualizados (v2 — julio 2026: 7 comisiones, red génesis-iniciativa, perfiles curados)	8
4.3.1 Insumos contruidos	8
4.3.2 M1 — Formación (Valued ERGM, red génesis-iniciativa)	9
4.3.3 M2 — Selección vs. influencia (panel, 7 comisiones)	10
4.3.4 M3 — Éxito legislativo (SDM, W génesis-iniciativa, DV y')	10
4.3.5 Robustez M1 y descomposición del vuelco de H1b	10
4.4 Limitaciones	11
5. Problemas identificados (registro detallado)	11
P1 — Cobertura incompleta de comisiones [RESUELTO 2026-07-07 — pipeline v2 con las 7 comisiones; resultados §4.3]	11
P2 — Definición de lazo inconsistente entre comisiones [RESUELTO 2026-07-07 — M1 con red génesis-iniciativa uniforme; indicaciones solo en ondas M2]	12
P3 — Reproducibilidad rota: rutas hardcodedas a carpetas legacy de otro repositorio [RESUELTO 2026-07-07 — scripts 00–08 reescritos sobre paths.{py,R}; pipeline corre de extremo a extremo desde este repo]	12

P4 — Normalización de nombres fragmentada (bug de las 155 filas) [RESUELTO 2026-07-07 — lib_names en todos los scripts; integrated_dataset con exactamente 154 filas por construcción]	12
P5 — Perfiles BCN incompletos [RESUELTO 2026-07-07]	13
P6 — Selección sobre la variable dependiente en M3 (ART-FALLIDO) [RESUELTO 2026-07-07 — DV principal y' con fracasos = 0 implementada; DV condicional como robustez]	14
P7 — Mapeo génesis→final recalculado desde insumos legacy [RESUELTO 2026-07-07 — script 04 v2 lee coincidencias con unión posicional al BORRADOR]	14
P8 — Heterogeneidades residuales en dataverse-final [PARCIAL — la mayoría resuelta aguas arriba 2026-07-07]	14
P9 — W y centralidades de M3 medidas sobre la red posterior al resultado [RESUELTO 2026-07-07 — W y centralidades sobre la red génesis-iniciativa]	15
P10 — dynIRT sin errores estándar [ABIERTO — prioridad baja]	15
P11 — ERGMs por comisión sin convergencia plena [RESUELTO 2026-07-07 — los 7 ERGMs por comisión convergen sobre las redes génesis-iniciativa (§4.3.5)]	15
P12 — Sin exportación de figuras ni tablas [PARCIAL — tablas exportadas a results/tables/ (M1–M3 + robustez); figuras pendientes]	15
P13 — Errores y desactualizaciones en los documentos del paper [ABIERTO]	15
P14 — Copias de insumos desincronizadas entre repos [RESUELTO 2026-07-07]	16
P15 — C2 sin autores: no podía entrar a la red de co-patrocinio [RESUELTO aguas arriba 2026-07-07, ronda 2]	16
6. Decisiones de diseño confirmadas	16
6.1 Puntos a revisar (no son problemas P)	18
7. Plan de actualización	18
8. Registro de cambios de este documento	18

1. Propósito de este documento

Este es el **reporte vivo** del proyecto: se actualiza a medida que el estudio avanza y registra, en un solo lugar, (i) los objetivos y el marco teórico, (ii) los datos y su procedencia exacta, (iii) el pipeline y los resultados vigentes, (iv) los **problemas identificados y su estado de resolución**, (v) las decisiones de diseño confirmadas, y (vi) el plan de trabajo. La versión v1 (julio 2026) documenta el estado del proyecto al momento de iniciar la **actualización de 5 a 7 comisiones** con los datos limpios de *dataverse-final* (PR #4 del repositorio de datos).

Convenciones: los problemas se etiquetan P1, P2, ... con estado [**ABIERTO**], [**RESUELTO**] o [**PARCIAL**]. Las rutas relativas refieren a este repositorio; el repositorio de datos se abrevia CPT (= B - constitutional-proposal-tracking, en <https://github.com/aoliveram/constitutional-proposal-tracking>).

2. Objetivos del proyecto

2.1 Contexto: la Convención Constitucional como experimento natural

La Convención Constitucional chilena (julio 2021 – julio 2022) es un caso excepcionalmente limpio para estudiar la **génesis de redes políticas**. A diferencia de una legislatura ordinaria, donde las redes de colaboración observadas son el sedimento de décadas de carreras compartidas, disciplinas de partido y expectativas de reelección, la Convención partió de un cuasi-*tabula rasa* organizacional:

1. **Actores mutuamente desconocidos.** De los 155 escaños, una mayoría inédita correspondió a independientes y outsiders sin trayectoria parlamentaria, electos por listas ad hoc y escaños reservados para pueblos originarios (17). Gran parte de los delegados no se conocía entre sí ni compartía socialización partidaria.

2. **Sin jerarquías heredadas.** No existían comités con seniority, liderazgos de bancada consolidados ni “sombra del futuro” electoral común: el órgano se disolvía al entregar el texto.
3. **Reglas endógenas.** La Convención escribió su propio reglamento, incluyendo el mecanismo central que explota este estudio: toda **iniciativa convencional constituyente** requería el patrocinio de **al menos 8 y no más de 16 convencionales** (Reglamento General, art. 83). El piso obliga a formar coaliciones mínimas para participar del proceso; el techo impide que las firmas se diluyan en mega-bloques y convierte cada patrocinio en un recurso escaso y estratégico.
4. **Horizonte comprimido.** Todo el ciclo — formación de lazos, negociación, producción normativa y resultado (el borrador del 14-05-2022) — ocurre en ~10 meses y está íntegramente documentado, con autoría explícita en cada iniciativa e indicación.

El co-patrocinio es, por tanto, un **proxy observable, costoso y fechado de colaboración política**, y la Convención permite observar el ciclo completo: cómo se forman los lazos entre extraños (RQ1), qué hacen esos lazos con las posiciones de los actores (RQ2), y cómo la posición en la red se traduce en éxito sobre el texto final (RQ3).

2.2 Preguntas de investigación

- **RQ1 — Formación.** ¿Qué factores impulsan la formación de la red de co-patrocinio cuando no existen jerarquías previas? ¿Domina la homofilia clásica (afiliación, género) o aparecen estrategias de diversificación?
- **RQ2 — Influencia vs. selección.** ¿La exposición a los co-autores desplaza las posiciones ideológicas de los delegados (influencia social), o los delegados seleccionan co-autores ya afines (selección endógena)?
- **RQ3 — Éxito.** ¿Cómo predice la estructura de red el éxito político individual, operacionalizado como **retención léxica**: cuánto del texto que un delegado patrocinó sobrevive en el borrador constitucional final?

2.3 Marco teórico

(Apartado en construcción: esta sección fija el esqueleto argumental y se irá puliendo junto con la especificación final de los modelos.)

(a) Formación de lazos en legislaturas: homofilia y sus límites. La literatura de co-sponsorship en legislaturas consolidadas (Fowler 2006; Bratton & Rouse 2011; Kirkland 2011) documenta con robustez que los lazos siguen líneas de partido, región y género — homofilia en el sentido de McPherson, Smith-Lovin & Cook (2001). Pero esa literatura no puede separar cuánto de la homofilia observada es preferencia y cuánto es estructura heredada (comités, bancadas, historia). La Convención remueve la estructura heredada: lo que se observe en la formación temprana refleja preferencias y estrategias de actores en un campo casi vacío. **H1a (línea base):** persiste homofilia por afiliación política agrupada, el clivaje más visible incluso entre independientes.

(b) Gatekeeping estratégico: la homofilia negativa de los “dotados”. Para los actores con recursos escasos y transversalmente valiosos — pericia jurídica (abogados, en una asamblea cuyo producto es un texto legal) y experiencia institucional previa — la teoría de brokerage (Burt 1992; Padgett & Ansell 1993) predice lo contrario de la homofilia: maximizan influencia **dispersándose** entre coaliciones, ocupando agujeros estructurales en vez de agruparse entre sí. Se comportan como *gatekeepers* del conocimiento procedimental. **H1b:** abogados y delegados con experiencia institucional exhiben homofilia *negativa* (co-patrocinan menos entre sí de lo esperado), condicional en los demás términos del modelo.

(c) Influencia social vs. selección endógena. Que los conectados se parezcan ideológicamente admite dos mecanismos generativos: influencia (los lazos mueven las posiciones; Friedkin & Johnsen 1990) o selección (las posiciones crean los lazos). Distinguirlos es el problema clásico de la econometría de redes (Shalizi & Thomas 2011; en la tradición SAOM, Steglich, Snijders & Pearson 2010). Nuestra estrategia: panel con efectos fijos individuales (toda heterogeneidad estable del delegado queda absorbida) más un **test de falsificación** con exposición futura (*lead*): si el efecto contemporáneo fuera influencia causal, la exposición futura no debería “predecir” el cambio pasado. **H2:** en un cuerpo con posiciones ideológicas pre-formadas (los delegados llegan

con identidades políticas adultas), domina la selección; el efecto de exposición desaparece bajo efectos fijos.

(d) El éxito legislativo como fenómeno colectivo. La efectividad legislativa suele tratarse como atributo individual (Volden & Wiseman 2014). Pero si la unidad de producción es la coalición firmante — y el reglamento fuerza que lo sea — el éxito debería *derramarse* por los lazos de co-autoría: mi retención léxica depende de la retención de aquellos con quienes escribo. Econométricamente eso es autocorrelación espacial en la variable de resultado sobre la topología de la red, y el marco natural son los modelos espaciales sobre redes (LeSage & Pace 2009). **H3:** la retención léxica exhibe dependencia de red fuerte; los modelos con rezago espacial (SAR/SDM) dominan al OLS, y el componente indirecto (spillover) de los efectos es sustantivo.

(e) Anclaje ideológico. Las posiciones ideológicas se estiman desde el comportamiento de votación nominal con un modelo dinámico de puntos ideales (dynIRT; Martin & Quinn 2002; implementación `emIRT` de Imai, Lo & Olmsted 2016), con prior de caminata aleatoria ($\omega^2 = 0.025$) y anclaje por dos delegados de posición pública inequívoca (Marinovic a la derecha, Baradit a la izquierda). Resultado: matriz $\Theta \in \mathbb{R}^{154 \times 91}$ (delegados $\times$ períodos de votación, 2021-07-13 a 2022-06-24).

2.4 Diseño: tres modelos

M1 — Formación (Valued ERGM). Red pooled de co-patrocinio con pesos $w_{ij} = \text{n}^\circ$ de documentos co-firmados. ERGM valuado con referencia Poisson:

$$P(W = w) \propto \exp\{\theta^\top g(w)\}, \quad g = (\text{sum}, \text{nodematch}_{\text{afiliación, abogado, experiencia, género, absdiff}_{\text{edad, grado, nodecov}_{\text{edad}}})$$

Los términos `nodematch` capturan homofilia (H1a) y su reverso (H1b). El término `absdiff` sobre el **grado académico** (escala ordinal 0–3: sin estudios universitarios terminados / educación superior terminada / magíster / doctorado; decisión 2026-07-07) prueba estratificación por credenciales educativas: un coeficiente negativo indica que la distancia educativa inhibe la co-firma.

M2 — Dinámica ideológica (panel FE). Sobre ondas temporales por comisión:

$$\Delta\theta_{i,t} = \alpha_i + \beta_1\theta_{i,t-1} + \beta_3 \text{NetExp}_{i,t-1} + \varepsilon_{it}, \quad \text{NetExp}_{i,t-1} = \frac{\sum_{j \neq i} w_{ij,t-1} \theta_{j,t-1}}{\sum_{j \neq i} w_{ij,t-1}}$$

con $w_{ij,t-1}$ = co-firmas acumuladas hasta la onda $t-1$. Comparación OLS agrupado vs. efectos fijos (within) vs. aleatorios (Hausman), errores agrupados por delegado, y falsificación con *lead*.

M3 — Éxito (Spatial Durbin Model). Con y_i = retención léxica media del delegado (similitud coseno TF-IDF génesis→final; robustez con Sentence-BERT) y W = matriz de co-autoría row-normalizada:

$$y = \rho W y + X\beta + W X \gamma + \varepsilon$$

Se compara OLS/SAR/SEM/SDM (AIC, Moran’s I) y se descomponen efectos directos/indirectos/totales.

3. Datos

3.1 Fuentes primarias (estado objetivo, post-actualización)

Desde 2026-07-07 los datos viven como **snapshot versionado dentro de este repositorio** (`data/raw/dataverse-final/`, copiado de CPT `paper-draft @ 5852519`; ver P14). El test de aceptación `code/0a-verify-dataverse-snapshot.py` valida cada refresco y escribe `QA-report.txt`.

Fuente	Ubicación	Contenido	N
Iniciativas génesis	<code>data/raw/dataverse-final/comisiones-originales/C{k}_GENESIS_master.js</code>	Licencias originales aprobadas en general	892

Fuente	Ubicación	Contenido	N
Trazabilidad completa	.../C{k}_TRACK_full.json	Artículos (incl. fallidos) con authors , history[] fechado y final_status al 100%	2.019
Trazabilidad filtrada	.../C{k}_TRACK_articles.json	Sólo artículos presentes en el borrador final	478
Borrador final	.../C{k}_BORRADOR_final.json	Artículos del borrador del 14-05-2022, por comisión	498
Mapeo maestro	data/raw/dataverse-final/contradictions/comisiones.csv	198 contradicciones, fuente(s): 298 identical, 146 similar, 54 not_traced	498
Codebook	data/raw/dataverse-final/dataverse-codebook-draft.md	Sección de article_uid, final_status, timestamp	—
Nombres canónicos	data/raw/convention_members.json	Referencia oficial “Apellido, Nombre”	154
Perfiles curados	data/raw/conventional-profiles.json (imputado dual-fuente; ver P5)	Características: género, afiliación, distrito, abogado, edad, grado (0–3), experiencia	154
Puntos ideales	data/raw/emirt/	Salidas dynIRT: Θ 154×91, metadata, posiciones resumen	154×91

Desglose por comisión del snapshot (TRACK_full = artículos + indicaciones sueltas; entre paréntesis, artículos con **authors**, la base de la red de co-patrocinio):

Comisión	Nombre oficial (corto)	GENESIS	BORRADOR	TRACK_articles	TRACK_full	Artículos (con authors)	Ind. sueltas
C1	Sistema Político	96	100	131	202	99 (99)	103
C2	Principios Constitucionales	312	41	24	182	182 (149)	0
C3	Forma de Estado	222	96	72	234	222 (222)	12
C4	Derechos Fundamentales	167	58	58	175	167 (150)	8
C5	Medio Ambiente	464	43	36	484	464 (420)	20
C6	Sistemas de Justicia	440	119	117	491	447 (418)	44
C7	Sistemas de Conocimientos	191	41	40	251	228 (218)	23

Comisión	Nombre oficial (corto)	GENESIS	BORRADOR	TRACK_article	TRACK_full	Artículos (con authors)	Ind. sueltas
Total		1.892	498	478	2.019	1.809 (1.676)	210

(Cifras post-ronda 2 de CPT (6fac4c4): *authors* de C2 poblado vía *sources*→firmantes de las iniciativas y de C4 vía *icc_id*, reglas validadas 1.415/1.416; el residuo de 134 registros sin autores queda documentado en el codebook — 65 de iniciativas populares/indígenas, 45 de ICC no recuperadas, 24 sin referencia de fuente.)

Nombres oficiales completos de las comisiones (verificados 2026-07-06 contra el registro oficial `cconstituyente.cl`, Wikipedia y UNESCO; ver P13):

1. Sistema Político, Gobierno, Poder Legislativo y Sistema Electoral
2. Principios Constitucionales, Democracia, Nacionalidad y Ciudadanía
3. Forma de Estado, Ordenamiento, Autonomía, Descentralización, Equidad, Justicia Territorial, Gobiernos Locales y Organización Fiscal
4. Derechos Fundamentales
5. Medio Ambiente, Derechos de la Naturaleza, Bienes Naturales Comunes y Modelo Económico
6. Sistemas de Justicia, Órganos Autónomos de Control y Reforma Constitucional
7. Sistemas de Conocimientos, Culturas, Ciencia, Tecnología, Artes y Patrimonios

3.2 Esquema de los datos de trazabilidad

Cada registro de artículo en `TRACK_full` contiene: `article_uid` (identificador único, guiones bajos), `article`, `timestamp` (formato MM-DD), `text`, `sources` (iniciativas de origen), `authors` (array "Apellido, Nombre"), `final_status` ("Idéntico a N.- ..." / "Similar a N.- ..." / "ART-FALLIDO"), y `history[]`. Cada entrada de `history[]` es una **indicación** fechada: `timestamp`, `step`, `number`, `authors`, `action` (ADD/DELETE/...), `target_scope`, `content`, `content_to_remove`, `placement_instructions`, `content_snapshot`.

Hechos estructurales que el pipeline absorbe (detalle en P8/P15):

- El esquema del GENESIS sigue **heterogéneo** entre comisiones (C1/C2/C3 sin `article_uid`; C4 sin `article/sources`; `authors` intermitente) — homogeneización pendiente en CPT; el loader unifica.
- Todos los `TRACK_full` salvo C2 contienen “**indicaciones sueltas**” (210 en total): registros de indicación al nivel superior con `action`, sin anclar a un artículo; 205/210 traen `authors + timestamp` y alimentan las ondas de M2. Los títulos de capítulo de C1 fueron eliminados aguas arriba (2026-07-07).
- `step` está normalizado a "Indicacion" (2.763 menciones; C2 conserva sus etiquetas de etapa propias). `timestamp` es MM-DD[-bloque] con año implícito 2022; hay 66 NA a nivel superior (C1 4, C3 2, C5 5, C6 17, C7 38) y 5 anidados.
- Los `authors` incluyen referencias a **iniciativas populares** (“7-2”, “Iniciativa Popular Indígena 21-2”): `code/lib_names.py` las clasifica como no-persona y las excluye de la red. Con esas reglas, las **75.616 menciones de autor-persona resuelven al 100%** contra los 154 canónicos (QA 0a, post-ronda 2).

3.3 Datos usados por la versión vigente (pre-actualización)

La versión reflejada en el extended abstract (abril 2026) usa insumos **anteriores** al PR #4 de limpieza, copiados en `data/raw/commissions/` (5 archivos: C1, C3, C5, C6, C7, enriquecidos a mano) y redes pre-construidas en `data/raw/network-visualization/`. Cifras vigentes: red pooled de **7.162 aristas**, **154 nodos**, **peso total 202.765**, **peso máximo 480**; ondas dinámicas solo para C1 (5), C3 (8) y C5 (6); mapeo génesis→final de **236 artículos** (125 idénticos + 111 similares; C1: 131, C3: 71, C5: 34); panel de **2.926** observaciones delegado-período; SDM sobre **141** casos completos.

3.4 Regla de asignación de covariables de perfil

Los perfiles de `data/raw/conventional-profiles.json` (154 filas, insumo de M1–M3) se construyen con la siguiente regla, ejecutada por `code/0b-audit-profiles-dual-source.py --impute` y documentada en `data/raw/profile-audit/README.md`:

1. **Extracción dual e independiente.** Para cada convencional, `gemini-3.5-flash` (con búsqueda web) extrae las características dos veces: desde el texto biográfico BCN ya scrapeado y desde su artículo de Wikipedia en español, con la instrucción de reportar la **situación al momento de ser convencional** (jul-2021 a jul-2022): afiliación vigente entonces, cargos previos al 04-07-2021.
2. **Regla de imputación.** *BCN es la fuente de verdad; si BCN no informa el dato, se usa Wikipedia; si ninguna informa, se conserva el valor base* (la salida del scraper). Cada celda de `profile_audit_table.csv` registra la concordancia entre fuentes ($=$, $\neq$, B, W, $\emptyset$).
3. **Validaciones humanas.** Las entradas de `manual_validations.json` (revisión manual del usuario sobre `discrepancias_pipeline.csv`) **siempre prevalecen** sobre la regla automática (p. ej. Chahin $\rightarrow$ DC pese a que BCN decía “Independiente”). Nuevas correcciones se agregan ahí y se re-imputa.
4. **Definiciones por campo.** `es_mujer`: género informado por la fuente (no inferido del nombre). `edad_al_asumir`: edad al 04-07-2021 desde la fecha de nacimiento. `afiliacion_agrupada`: partido con militancia vigente durante la Convención, o “Independiente”; los escaños reservados llevan su afiliación partidaria real (o Independiente) y el pueblo queda en `distrito` = “Escaño reservado: <pueblo>”. `es_abogado`: profesión de abogado/a. `grado_academico_nivel` (escala 0–3): 0 sin estudios universitarios terminados; 1 educación superior terminada (título profesional o licenciatura); 2 magíster/máster (no cuenta diplomado); 3 doctorado. `experiencia_previa_institucional`: 1 si antes de jul-2021 ocupó cargos públicos (parlamentario/a, alcalde/sa, concejal/a, CORE, seremi, intendente/a, ministro/a, subsecretario/a, embajador/a, jefatura de servicio).

Estado vigente: 154/154 perfiles, 0 afiliaciones desconocidas, 0 edades faltantes; grado 0–3 = {0: 18, 1: 81, 2: 41, 3: 14}.

4. Pipeline y resultados

4.1 Scripts

Pipeline v2 (2026-07-07): todos los scripts derivan rutas de `code/paths.{py,R}` y nombres de `code/lib_names.{py,R}`; los insumos son el snapshot `data/raw/dataverse-final/` y los perfiles curados (§3.4).

#	Script	Rol	Outputs
0a	<code>code/0a-verify-dataverse-snapshot.py</code>	Verificación del snapshot	<code>QA-report.txt</code>
0b	<code>code/0b-audit-profiles-dual-source.py</code>	Auditoría de fuente e imputación de perfiles (§3.4)	<code>conventional-profiles.json</code> , <code>profile-audit/*</code>
00	<code>code/00-build_dynamic_networks.py</code>	Región de iniciativas; redes génesis (iniciativa y artículo); ondas $\times 7$ con dedup de indicaciones	<code>genesis_network_{initiative,article}</code> , <code>initiative_registry.csv</code> , <code>C{k}_dynamic_networks.json</code> , <code>commission_waves.csv</code>
01	<code>code/01-model-valued-ergm.py</code>	ML: Valued ERGM Poisson (red iniciativa) + centralidades	<code>ergm_pooled_results.rds</code> , <code>network_metrics.csv</code> , <code>tables/M1_ergm_iniciativa.csv</code>
02	<code>code/02-extract-emirt-temporal.py</code>	Abstracción temporal $\Theta \leftrightarrow \Theta$ en ondas de las 7 comisiones	<code>emirt_*.csv</code>

#	Script	Rol	Outputs
03	code/03-model-network-influence	M2: panel FE/RE/OLS + falsificación <i>lead</i> + robusteces de ventana (decaimiento, última onda, por día)	network_exposure_panel.csv, panel_regression_results.rds, tables/M2_panel.csv
04	code/04-build-article-mapping	M1: grupo de coincidencias (unión posicional al BORRADOR) + desenlaces por artículo	article_mapping_unified.csv, track_article_outcomes.csv
05	code/05-nlp-text-similarity	M2: repetición léxica TF-IDF + SBERT; DV y' con fracasos = 0	article_similarity_scores.csv, author_success_scores.csv
06	code/06-build-integrated-dataset	M3: <i>dataset</i> <i>by</i> -driven (154 filas por construcción)	integrated_dataset.{csv,json}
07	code/07-model-spatial-duration	M1: <i>W</i> génesis-iniciativa; Moran; OLS/SAR/SEM/SDM; impactos	sdm_results.rds, tables/M3_*.csv
08	code/08-robustness-checks	M1: robustez M1 (por comisión $\times 7$, unidad artículo, perfiles pre-auditoría) y M3 (DV antigua, <i>W</i> binaria, <i>W</i> artículo, SBERT)	robustness_results.rds, tables/M{1,3}_robustness.csv

4.2 Resultados de la versión anterior (extended abstract, abril 2026 — 5 comisiones, red mixta, perfiles heurísticos)

- **M1.** `nodematch`(afiliación) = +0.41; `nodematch`(abogado) = −0.09; `nodematch`(experiencia) = −0.12; `nodematch`(mujer) = +0.08; `nodecov`(edad) = −0.024. Lectura: homofilia positiva de afiliación y género; **homofilia negativa** de abogados y experimentados (gatekeeping estratégico, H1b confirmada).
- **M2.** OLS agrupado: $\hat{\beta}_3 = +0.033$ ($p < 0.001$); efectos fijos: $\hat{\beta}_3 = +0.0004$ ($p = 0.91$); Hausman $\chi^2 = 784.96$ ($p < 0.001$) → FE. Falsificación con *lead* significativa ($p < 0.001$) → **selección, no influencia** (H2 confirmada).
- **M3.** Moran's $I = 0.155$ ($p < 10^{-6}$). AIC: OLS −338.5 < SEM −354.8 ($\lambda = 0.81$) < SAR −355.3 ($\rho = 0.89$) < **SDM** −383.4 ($\hat{\rho} = 0.997$). En OLS: `theta_mean` +0.012 ($p = 0.008$), `theta_sd` −0.103 ($p = 0.015$), `ego_heterophily` −0.063 ($p = 0.027$); centralidades n.s. Validación de medida: artículos “idénticos” puntúan 0.979 en TF-IDF. Robustez: SBERT preserva signos; con *W* binaria ρ cae a 0.374 manteniendo significancias clave (H3 confirmada).

4.3 Resultados actualizados (v2 — julio 2026: 7 comisiones, red génesis-iniciativa, perfiles curados)

4.3.1 Insumos construidos

Registro de iniciativas (`initiative_registry.csv`): **528 iniciativas** con ≥ 2 firmantes-persona — C1: 29, C2: 56, C3: 41, C4: 68, C5: 148, C6: 78, C7: 108 (las iniciativas populares/indígenas quedan fuera de la red de personas). **Red génesis-iniciativa** (principal): 154 nodos (sin aislados), **7.731 aristas**, peso total 53.391, peso máximo 76. **Red génesis-artículo** (robustez): 1.676 eventos de co-firma, 8.020 aristas, peso 175.316.

Ondas para M2 (T0 génesis + fechas observadas de indicaciones; los duplicados de una misma indicación repetida en el `history[]` de varios artículos se colapsan a un acto):

Comisión	Ondas de indicaciones	Eventos con lazos	Unipersonales	Duplicados colapsados
C1	4	266	99	45
C2	3	1	52	0
C3	6	212	29	166
C4	5	154	241	49
C5	5	0	559	0
C6	6	317	64	291
C7	8	54	278	178

Las indicaciones son mayoritariamente unipersonales en varias comisiones (C5: todas): no forman lazos pero sí definen la línea temporal; las ondas de C5 son *planas* (la red no cambia tras T0), igual que en la versión anterior.

Mapeo y DV de éxito: 484 pares génesis→final (480 vía *coincidencias* + 4 rescatados parseando `final_status`; 2 uids de indicación no encontrados). Desenlaces de los 1.809 artículos: 223 idéntico, 136 similar, 275 ART-FALLIDO, 1.175 eliminado (fracaso = fallido + eliminado, $\text{sim} = 0$). **Validación del emparejamiento:** similitud alineada 0.554 vs. 0.032 con pares barajados; 96.5% de los pares supera su baseline. TF-IDF idéntico 0.570 / similar 0.565; SBERT 0.857 / 0.872. *Nota sobre el ancla de validación:* la v1 reportaba 0.979 en “idénticos” porque comparaba el texto **post-indicaciones** con el borrador; la v2 usa el texto **génesis verdadero** (la operacionalización correcta de “retención de lo que el delegado propuso”), y la etiqueta idéntico/similar — que refiere al estado *final* del artículo — deja de ordenar la similitud génesis→final; la validación pasa a ser el contraste alineado-vs-barajado. Media de y' : 0.094; tasa de supervivencia media: 0.211; **154/154 convencionales con score** (el dataset integrado tiene 154 casos completos: por primera vez el roster entero entra a M3).

4.3.2 M1 — Formación (Valued ERGM, red génesis-iniciativa)

Término	Estimación	EE	p
sum	+1.498	0.027	$< 10^{-4}$
nodematch afiliación	+0.577	0.010	$< 10^{-4}$
nodematch experiencia previa	+0.435	0.011	$< 10^{-4}$
nodematch abogado	+0.156	0.009	$< 10^{-4}$
nodematch mujer	+0.142	0.009	$< 10^{-4}$
absdiff edad	−0.0005	0.0005	0.32
absdiff grado académico (0–3)	−0.048	0.006	$< 10^{-4}$
nodecov edad	−0.008	0.0003	$< 10^{-4}$

Cambio sustantivo respecto de la v1: H1b se invierte. Con la red génesis limpia y los perfiles curados, abogados y delegados con experiencia institucional muestran homofilia **positiva** (antes: -0.09 y -0.12) — el hallazgo de “gatekeeping estratégico” de la v1 no sobrevive a la corrección de datos. H1a se refuerza (afiliación $+0.577$ vs. $+0.41$). El término nuevo **absdiff(grado)** es negativo y significativo: la **distancia educativa inhibe la co-firma** (estratificación por credenciales), y **nodecov(edad)** negativo indica que los mayores co-firman menos en volumen. *Caveat técnico:* el MCMLE del ERGM pooled converge al 95% pero no al 99% de confianza ($p = 0.014$ del test de convergencia tras 60 iteraciones); los coeficientes son estables entre corridas pero el caveat queda registrado.

4.3.3 M2 — Selección vs. influencia (panel, 7 comisiones)

Panel: **4.278 observaciones** delegado-onda (antes 2.926), 154 delegados, 7 comisiones; 1.078 celdas cuyo paso comparte período emIRT con el anterior ($\Delta\theta \equiv 0$ mecánico) se excluyen. Coeficiente de exposición ($\hat{\beta}_3$), EE agrupados por delegado:

Modelo	$\hat{\beta}_3$	EE	p
OLS agrupado	+0.0356	0.0099	3.1×10^{-4}
Efectos fijos (within)	−0.0007	0.0045	0.88
OLS + FE de comisión	+0.0364	0.0095	1.4×10^{-4}
Falsificación (<i>lead</i>)	+0.0552	0.0116	2.2×10^{-6}
FE, exposición con decaimiento ($\lambda = 0.5$)	+0.0017	0.0045	0.71
FE, exposición solo-última-onda	+0.0068	0.0128	0.60
FE, $\Delta\theta$ por día	−0.0001	0.0004	0.83

Hausman $\chi^2 = 1973.9$ ($p \approx 0$) $\rightarrow$ FE. **El resultado central de la v1 se replica y blinda:** la correlación positiva desaparece bajo efectos fijos, la exposición futura “predice” el cambio pasado (falsificación falla $\rightarrow$ selección endógena), y el nulo bajo FE sobrevive las tres ventanas alternativas de exposición. H2 confirmada con el doble de observaciones y las 7 comisiones.

4.3.4 M3 — Éxito legislativo (SDM, W génesis-iniciativa, DV y')

$N = 154$ (casos completos). Moran’s $I = 0.380$ ($p \approx 10^{-194}$; antes 0.155). Comparación (AIC): OLS $-448.9 < \text{SEM} -529.5$ ($\lambda = 0.981$) $< \text{SAR} -539.3$ ($\rho = 0.979$) $< \text{SDM} -575.5$ ($\hat{\rho} = 0.943$). En OLS, con la DV nueva la **posición de red predice éxito: degree** +0.0012 ($p = 0.002$), **betweenness** −0.0011 ($p = 0.004$) — en la v1 las centralidades eran n.s. En el SDM los efectos directos individuales se disipan y los términos **contextuales** son los significativos (**lag.degree** +0.009, **lag.betweenness** −0.008, **lag.es_mujer** −0.175, **lag.theta_mean** +0.093): el éxito propio depende de los atributos de los co-firmantes. H3 confirmada y amplificada. *Nota:* con ρ cercano a 1, la descomposición directo/indirecto de los impactos es numéricamente inestable (SEs simuladas explotan); se reportan coeficientes y ρ , y los impactos quedan en el **.rds**. Parte del derrame es mecánica — los co-firmantes comparten artículos y por tanto componentes de y' — lo que refuerza la lectura “el éxito es colectivo” pero impide interpretar ρ como influencia pura (ver Limitaciones).

Robustez M3 (tabla **M3_robustness.csv**): la dependencia espacial sobrevive todas las variantes — DV condicional antigua ($I = 0.140$, $\rho = 0.840$), W binaria ($\rho = 0.794$), W artículo ($I = 0.408$, $\rho = 0.934$), DV SBERT ($\rho = 0.937$).

4.3.5 Robustez M1 y descomposición del vuelco de H1b

Los **9 ERGMs de robustez convergieron** (los 7 por comisión — antes C3 y C5 no convergían: P11 resuelto — más las dos variantes pooled). Coeficientes clave (**M1_robustness.csv**; *** $p < 0.001$, ** $p < 0.01$, * $p < 0.05$):

Modelo	nodematch afiliación	nodematch experiencia	nodematch abogado	absdiff grado
C1 Sistema Político	+0.511***	−0.175**	−0.018	+0.192***
C2 Principios	+0.428***	+0.655***	+0.298***	+0.032
C3 Forma de Estado	+0.505***	−0.207***	−0.071*	−0.027
C4 Derechos Fundamentales	+0.502***	+0.530***	+0.267***	+0.105***
C5 Medio Ambiente	+0.812***	+0.399***	+0.171***	−0.237***

Modelo	nodematch afiliación	nodematch experiencia	nodematch abogado	absdiff grado
C6 Sistemas de Justicia	+0.673***	+0.405***	+0.001	-0.051***
C7 Conocimientos	+0.345***	+0.672***	+0.217***	-0.020
Pooled unidad artículo	+0.844***	+0.531***	+0.187***	-0.041***
Pooled iniciativa, perfiles pre-auditoría	+0.181***	+0.370***	+0.212***	+0.009

Descomposición del vuelco. Con los perfiles *antiguos* (pre-auditoría) sobre la red nueva, la homofilia de experiencia y abogados **sigue siendo positiva**: el vuelco de H1b **no** proviene de la corrección de covariables sino del **cambio de red** — génesis puro (sin indicaciones) y cobertura de 7 comisiones. La corrección de perfiles sí explica otra cosa: la homofilia de afiliación salta de +0.181 (con 33 “Desconocida” y falsos independientes) a +0.577 (curada) — el ruido de medición diluía el clivaje político.

El patrón fino es heterogéneo y sustantivamente rico: la homofilia *negativa* de experiencia sobrevive **exactamente en C1 (Sistema Político) y C3 (Forma de Estado)** — las comisiones donde se diseñaba la arquitectura del poder, dominantes en la muestra antigua — mientras en las otras cinco es fuertemente positiva. La lectura de gatekeeping de la v1 no era un fantasma: es un fenómeno **específico de las comisiones de diseño institucional**, no una estrategia general. La unidad iniciativa vs. artículo no altera ninguna conclusión (§6.1).

4.4 Limitaciones

1. **C2 delgada en la dinámica (M2).** Por la naturaleza distinta de la comisión y de su registro, C2 aporta solo 3 ondas con 1 evento de co-firma de indicaciones (52 unipersonales) y su génesis cubre 149/182 artículos. Decisión del usuario (2026-07-07): **se usa de todas formas**; su contribución a M2 es mínima y así debe leerse.
2. **Ondas planas en C5.** Todas sus indicaciones con autor son unipersonales: la red de C5 no cambia después de T0, y su aporte a M2 proviene de la variación temporal de θ , no de cambios de red (igual que en la v1).
3. **Cobertura de autores.** 134/2.019 registros TRACK sin autores (65 de iniciativas populares/indígenas — patrocinio institucional —, 45 de ICC no recuperadas, 24 sin referencia); 54 artículos del borrador final quedaron `not_traced` en coincidencias; 66 + 5 registros *undated* se excluyen de las ondas.
4. **Convergencia del ERGM pooled.** MCMLE al 95% pero no al 99% (ver §4.3.2).
5. **Ancla de validación NLP.** El cambio de texto post-indicaciones → texto génesis hace incomparables las medias de similitud v1 vs. v2 (0.979 vs. 0.570 en “idénticos”); la validez del emparejamiento se establece ahora por el contraste alineado-vs-barajado (0.554 vs. 0.032).
6. **Derrame parcialmente mecánico en M3.** y' de co-firmantes comparte artículos por construcción; ρ combina interdependencia real y composición compartida del DV. La extensión artículo-onda (M4 futura) es el camino para separarlas.
7. **dynIRT sin errores estándar** (P10, abierto): la incertidumbre de θ no se propaga a M2/M3.

5. Problemas identificados (registro detallado)

Esta sección es el inventario completo de defectos, deudas y decisiones pendientes detectados en la auditoría de julio 2026 (previa a la actualización). Es la lista de control contra la cual se ejecutará el plan de la §7.

P1 — Cobertura incompleta de comisiones [RESUELTO 2026-07-07 — pipeline v2 con las 7 comisiones; resultados §4.3]

Situación. La versión vigente usa 5 de las 7 comisiones en M1 (C1, C3, C5, C6, C7; C2 y C4 ausentes del repo) y solo 3 en M2 y M3 (C1, C3, C5), porque los archivos antiguos de C6/C7 no tienen `final_status` ni ondas temporales. El propio abstract lo declara como limitación (“Ongoing work”).

Consecuencias. (i) La red pooled subestima lazos formados vía C2/C4 — con 312 y 167 iniciativas génesis, no son comisiones menores; C4 (Derechos Fundamentales) fue además la comisión políticamente más cargada. (ii) El mapeo de éxito cubre 236 de 498 artículos finales (47%): la DV de M3 ignora más de la mitad del borrador. (iii) El panel de M2 descarta la dinámica de 4 comisiones.

Solución. Migrar todo el pipeline a los `dataverse-final` de las 7 comisiones (PR #4 de CPT, mergeado): GENESIS para la red de co-patrocinio, TRACK_full para ondas e indicaciones, `coincidencias_comisiones.csv` + BORRADOR_final para el éxito.

P2 — Definición de lazo inconsistente entre comisiones [RESUELTO 2026-07-07 — M1 con red génesis-iniciativa uniforme; indicaciones solo en ondas M2]

Situación. En `code/00-build_dynamic_networks.py`, la red pooled suma la **última onda acumulada** de C1/C3/C5 (= génesis + **todas las indicaciones**, líneas 175–178) pero solo el génesis de C6/C7 (líneas 194–204). La red que estima M1 — y que M3 usa como *W* y para las centralidades — mezcla, por tanto, dos definiciones de lazo según la comisión.

Consecuencias. Los pesos no son comparables entre comisiones (C5 aporta 4.968 aristas acumuladas vs. C7 solo génesis); los coeficientes del ERGM confunden formación primaria con colaboración posterior.

Solución (decisión 2026-07-06). M1 usará exclusivamente la red génesis de las 7 comisiones: modela la *formación primaria* de lazos entre desconocidos, y el co-patrocinio de iniciativas es el acto fundacional (además, con umbral reglamentario 8–16 firmas, es un compromiso costoso y acotado). Las indicaciones entran solo a las **ondas acumuladas** de M2 (colaboración posterior, condicionada por la red ya formada). Para M3, ver P9. Robustez: red génesis+indicaciones como variante.

P3 — Reproducibilidad rota: rutas hardcodedas a carpetas legacy de otro repositorio [RESUELTO 2026-07-07 — scripts 00–08 reescritos sobre paths.{py,R}; pipeline corre de extremo a extremo desde este repo]

Situación. Los scripts 02–05 leen desde rutas absolutas del repo CPT, y además desde carpetas **legacy previas a la limpieza**: 02-extract-emirt-temporal.R:10 (`emIRT-analysis/`, escribe a `playground/research-proposal-implementation/data`), 03-model-network-influence.R:30–32 (`conventionals-bcn-webscrapping/`, `network-visualization/`), 04-build-article-mapping.py:15–22 (`comision-N/draft-after-indications-manual/`, `proposals/draft_final_text.json`), 05-nlp-text-similarity.py:2. El archivo `draft_final_text.json` ni siquiera existe en este repositorio. Los scripts 00, 01, 06, 07, 08 sí leen de `data/` local.

Consecuencias. El pipeline no corre de extremo a extremo desde este repo; los outputs commiteados en `data/processed/` no son regenerables por terceros; y los insumos legacy quedaron desactualizados respecto de `dataverse-final`.

Solución (ejecutada 2026-07-07 en su mitad de infraestructura). Snapshot copiado a `data/raw/dataverse-final/comision-{1..7}/` (CPT paper-draft @ 5852519, con README de procedencia y test de aceptación `code/0a-verify-dataverse-snapshot.py`); módulos centrales `code/paths.py` / `code/paths.R` creados. **Queda:** recablear los scripts 00–08 para que deriven todas sus rutas de esos módulos (se hará al reescribirlos en la actualización de modelos).

P4 — Normalización de nombres fragmentada (bug de las 155 filas) [RESUELTO 2026-07-07 — lib_names en todos los scripts; integrated_dataset con exactamente 154 filas por construcción]

Situación. El mapa NAME_CORRECTIONS (5 correcciones: Muñoz/Sepúlveda×2/Vargas-typo/Chinga) vive solo en `code/00-build_dynamic_networks.py`:35–41. El pipeline de éxito (04→05→06) corre sin esa normalización, así que "Sepúlveda, Barbara" (con tilde, desde los archivos de comisión) no cruza con

"Sepulveda, Barbara" (canónico) y `integrated_dataset.csv` termina con **155 filas** en vez de 154: la misma persona partida en dos, con métricas de red en una fila y score de éxito en otra.

Consecuencias. Una observación duplicada/incompleta en M3; `author_success_scores.csv` registra 149 "autores" con al menos un fantasma.

Solución (módulos creados 2026-07-07). `code/lib_names.py` y `code/lib_names.R`: correcciones explícitas (incl. nombres invertidos tipo "Dayyana, Gonzalez"), match normalizado sin tildes, resolución de apellido único ("Roa" → "Roa, Giovanna"), y clasificación de **no-personas** (iniciativas populares registradas como autor). Verificado sobre el snapshot completo: 70.043 menciones, 100% de las personas resuelven a los 154 canónicos; el QA 0a falla si aparece un string nuevo no resuelto. **Queda:** que los scripts del pipeline usen este módulo al reescribirse (elimina el bug Sepúlveda/155 filas por construcción).

P5 — Perfiles BCN incompletos [RESUELTO 2026-07-07]

Situación original. `conventional-profiles.json` tenía **147/154** perfiles. Los 7 ausentes (Botto, Castillo M.T., González D., Reyes M.R., Rivera M.M., Tepper, Zúñiga L.A.) recibían valores por defecto (edad 45, flags 0, afiliación "Desconocida") en los scripts.

Diagnóstico (resuelto). `match_names()` en `CPT/conventionals-bcn-webscrapping/fetch_convencionales.py` exigía que el campo *nombre de pila completo* fuera substring contiguo del directorio BCN. La BCN registra un solo nombre de pila y a veces el **segundo** ("Ramona" Reyes, "Angélica" Tepper, "Arturo" Zúñiga), y en un caso con ortografía distinta ("Dayyana" González). **Fix aplicado 2026-07-06:** matching en tres niveles (campo completo → cualquier token exacto del nombre de pila → `fuzzy difflib ≥ 0.85`), verificado: 154/154 matcheados, **0 cambios de URL** en los 147 previos, re-scraping completo ejecutado. `conventional-profiles.json` tiene ahora **154 perfiles**; los 7 recuperados traen género, distrito y edad correctos.

Pendiente (auditoría manual de covariables).

1. **Afiliación "Desconocida" (33/154).** Incluye políticos de militancia pública y conocida (Chahin, Monckeberg, Larraín, Celis, Mayol...): es un fallo de extracción de la ficha BCN (la propiedad semántica `bcnbio:ofNamedPoliticalParty` no siempre está), no independencia real. Dado que `nodematch(afiliación)` es un término central de M1, **debe completarse a mano**.
2. **Falsos "Independiente".** La heurística de respaldo de `process_profiles.py` (busca "Independiente" en la trayectoria textual) produce falsos positivos: p. ej. asignó "Independiente" a Arturo Zúñiga (militante UDI). La auditoría debe validar también los "Independiente" de figuras con militancia conocida.
3. **Faltantes enmascarados.** `es_mujer`, `es_abogado`, `grado_academico_nivel` y `experiencia_previa_institucional` no admiten NA: el default 0 significa "no detectado por la heurística de texto", no "negativo confirmado" (p. ej. `es_mujer` se infiere de terminación en "-a" o palabras como "casada"). Riesgo directo sobre H1b (abogados, experiencia). Auditar al menos esos dos campos.
4. **Distrito "Desconocido" (9/154).** Aguilera, Bacián, Chinga, Galleguillos, Godoy, González L., Jiménez, Tirado, Vargas M. — todos **escaños reservados de pueblos originarios no mapuche**: no es dato faltante; recodificar como "Escaño reservado".
5. **Edad (1/154).** Renato Garín sin fecha de nacimiento en BCN; completar a mano.

Auditoría dual-fuente ejecutada (2026-07-06). `code/0b-audit-profiles-dual-source.py` consulta `gemini-3.5-flash` (API Gemini con *search grounding*): para cada convencional extrae las características dos veces, de forma independiente — desde el texto BCN ya scrapeado y desde su artículo de Wikipedia en español — referidas al período de la Convención. Outputs en `data/raw/profile-audit/`: tabla de símbolos 154×8 (= coinciden, ≠ discrepan, B/W una sola fuente, ∅ ninguna), valores por fuente, y `discrepancias_pipeline.csv`. Resultados de la corrida v1 (lotes de 5): 154/154 auditados, ~124 con artículo de Wikipedia; **135 discrepancias** con el pipeline: afiliación 62 (resuelve las 33 "Desconocida" — Monckeberg→RN, Larraín→Evópoli, etc. — y detecta falsos "Independiente": Zúñiga→UDI), grado académico 29, experiencia previa 24, distrito 17 (incluye los 9 escaños reservados), género 1, edad 1 (Garín: 35), abogado 1.

Cierre (2026-07-07). Tras la validación manual del usuario sobre las primeras ~36 discrepancias (registrada en `manual_validations.json`), se ejecutó la **corrida v2** (lotes de 6, grado académico en escala 0-3; carpeta `profiles-batches/`) y se automatizó la **imputación** con la regla del usuario: *BCN es ground truth; si BCN no informa, Wikipedia; si ninguna, valor base; las validaciones manuales siempre prevalecen*. Chequeo de consistencia v1 vs. v2 (`runs_consistency.csv`): 100% de acuerdo en género, fecha, distrito y experiencia; 99.6% abogado; 97.5% lista; 96.0% grado (mapeando escalas); 93.5% afiliación — los desacuerdos residuales quedan listados para inspección. Las 6 validaciones de grado hechas bajo la escala antigua (1 = magister) se recodificaron a 2 en la escala nueva (ambas corridas corroboran magister); los distritos de escaños reservados se estandarizaron a “Escaño reservado: <pueblo>”. Resultado vigente en `data/raw/conventional-profiles.json`: **154 perfiles** (incluye a Botto y los otros 6 recuperados), **0 afiliaciones “Desconocida”**, 0 edades faltantes, grado 0-3 = {0: 18, 1: 81, 2: 41, 3: 14}. Validaciones manuales en conflicto con la regla automática que se preservaron: Chahin→DC (BCN decía “Independiente”) y Arrau→Republicano (la v2-BCN leyó UDI). Nuevas correcciones futuras se agregan a `manual_validations.json` y se re-corre `--impute`.

P6 — Selección sobre la variable dependiente en M3 (ART-FALLIDO) [RESUELTO 2026-07-07 — DV principal y' con fracasos = 0 implementada; DV condicional como robustez]

Situación. La DV vigente promedia la similitud solo sobre los artículos **mapeados** al borrador final:

$$y_i = \frac{1}{|M_i|} \sum_{a \in M_i} \text{sim}(a), \quad M_i = \{a \in A_i : \text{final_status} \in \{\text{Idéntico}, \text{Similar}\}\}$$

Los artículos fallidos no entran ni al numerador ni al denominador. Consecuencias: (i) y_i mide retención *condicional a sobrevivir* — un delegado con 1/10 iniciativas sobrevivientes idénticas puntúa igual que uno con 10/10; (ii) los delegados cuyos artículos fallaron todos salen de la muestra (parte de la caída a $N = 141$): selección clásica sobre la DV.

Solución (decisión confirmada 2026-07-06). Con `final_status = ART-FALLIDO` disponible en las 7 comisiones, la DV principal pasa a incluir los fallidos con similitud 0:

$$y'_i = \frac{1}{|A_i|} \sum_{a \in A_i} \text{sim}(a) = \underbrace{\frac{|M_i|}{|A_i|}}_{\text{tasa de supervivencia } \hat{s}_i} \times \underbrace{\overline{\text{sim}}_{M_i}}_{\text{retención condicional } \bar{r}_i}$$

es decir, retención esperada por iniciativa presentada. La DV antigua queda como robustez; si la masa de ceros resulta grande, se agrega un modelo en dos partes ($\hat{s}_i$ y $\bar{r}_i$ por separado) como chequeo.

P7 — Mapeo génesis→final recalculado desde insumos legacy [RESUELTO 2026-07-07 — script 04 v2 lee coincidencias con unión posicional al BORRADOR]

Situación. `04-build-article-mapping.py` reconstruye el mapeo leyendo `draft-after-indications-manual/` (legacy, solo C1/C3/C5) y filtrando `final_status` con `matching` de strings; produce 236 artículos mapeados.

Solución (decisión 2026-07-06). `CPT/coincidencias_comisiones.csv` — curada a mano en el PR #4, en UTF-8, con los **498** artículos del borrador final, su comisión de origen, estatus (`identical/similar`), y fuentes múltiples (primaria/secundaria/terciaria) — pasa a ser la **fuentes de verdad** del mapeo. El script 04 se reduce a un lector/validador de esa tabla; los textos finales se toman de los `C{k}_BORRADOR_final.json`.

P8 — Heterogeneidades residuales en `dataverse-final` [PARCIAL — la mayoría resuelta aguas arriba 2026-07-07]

Estado tras la revisión del usuario en CPT (`paper-draft @ 5852519`) y el QA del snapshot:

1. **[RESUELTO aguas arriba]** Títulos de capítulo de C1 eliminados (TRACK_full 230 → 202; typo "tite" desapareció con ellos); `article_uid` y `final_status` al **100%** tras la armonización de ids (f8b9ddc); `step` normalizado a "Indicacion" en todos los niveles (3.205 reemplazos; C2 conserva sus etiquetas propias); nombres de archivo GENESIS unificados a `C{k}_GENESIS_master.json`; semántica de `timestamp` documentada en el codebook (MM-DD, año implícito 2022, sufijo `-{bloque}` = n-ésimo informe del día).
2. **[ABIERTO — CPT]** Esquema GENESIS aún heterogéneo (C1/C2/C3 sin `article_uid`; C4 sin `article/sources`; `authors` intermitente); asignado en CPT con la instrucción de heredar los uids de TRACK/crosswalk. El loader de este repo lo absorbe mientras tanto.
3. **[ABIERTO — loader]** Indicaciones sueltas (210): se mantiene la decisión — alimentan las ondas de M2 (205/210 con `authors+timestamp`), no entran a M1 ni a M3. Falta la aserción de no-duplicación contra `history[]` en el loader.
4. **[RESUELTO aguas arriba — ronda 2]** Timestamps sin fecha: los 66 top-level + 5 anidados quedaron documentados como *undated* en el codebook (49e394e); no se imputan (recuperarlos exigiría volver a los PDF de origen). En M2, los registros sin fecha se reportan y se excluyen de las ondas.

P9 — *W* y centralidades de M3 medidas sobre la red posterior al resultado [RESUELTO 2026-07-07 — *W* y centralidades sobre la red génesis-iniciativa]

Situación. La *W* del SDM y las covariables `degree/betweenness` se calculan sobre la red pooled acumulada final, que incluye lazos formados durante todo el proceso — en parte *después* de los eventos que determinaron la suerte de los artículos. Simultaneidad estructura ↔ resultado.

Solución (decisión 2026-07-06). Medir *W* y las centralidades sobre la **red génesis** (coherente con P2): la estructura precede al resultado. La red acumulada queda como robustez. Extensión futura (M4, no compromete el paper actual): modelo de supervivencia a nivel artículo-onda, con la posición de red de los autores en la red vigente en cada onda — los datos lo permiten (timestamps de indicaciones en las 7 comisiones, `voting_result`, `final_status`; el momento de muerte de un fallido se aproxima con su última aparición en el historial).

P10 — dynIRT sin errores estándar [ABIERTO — prioridad baja]

No existe `emIRT_bootstrap_output.rds`; `theta_se` queda NA en el pipeline (el script 02 lo tolera). Decidir si (i) bootstrap paramétrico del dynIRT, o (ii) reportar sensibilidad de M2 a la incertidumbre de θ de otro modo. No bloquea la actualización.

P11 — ERGMs por comisión sin convergencia plena [RESUELTO 2026-07-07 — los 7 ERGMs por comisión convergen sobre las redes génesis-iniciativa (§4.3.5)]

En la robustez vigente, los Valued ERGM de C3 y C5 no convergieron plenamente (muestras chicas a nivel de comisión). Con 7 comisiones el problema puede repetirse en las nuevas; plan: reintentar con los datos nuevos y, si persiste, reportar solo el pooled + los que converjan, documentándolo.

P12 — Sin exportación de figuras ni tablas [PARCIAL — tablas exportadas a results/tables/ (M1–M3 + robustez); figuras pendientes]

`results/figures/` y `results/tables/` están vacíos; las tablas del extended abstract están escritas a mano en el `.tex`. Riesgo de divergencia silenciosa entre resultados y paper (ya ocurrió: el abstract dice “max weight > 300” cuando el máximo real es 480; ver P13.3). Plan: cada script de modelo exporta sus tablas (CSV + LaTeX) y figuras a `results/`, y el `.tex` las incluye en vez de duplicarlas.

P13 — Errores y desactualizaciones en los documentos del paper [ABIERTO]

1. **Rótulos temáticos de comisiones equivocados.** `docs/extended-abstract.tex` (§Data) describe “C5: Fundamental Rights; C6: Environment”. Según la numeración oficial (verificada; §3.1), C5 es

Medio Ambiente y C6 es **Sistemas de Justicia** (Derechos Fundamentales es C4, que no estaba en la muestra). La numeración de los archivos es consistente con la oficial; son los rótulos temáticos del texto (y del README) los que están corridos.

2. **“155 delegates” vs. 154** en pasajes del abstract y propuesta (154 es el n tras normalización de nombres; la Convención tuvo 155 escaños — precisar la distinción donde corresponda).
3. **Cifras a regenerar** tras la actualización: todas las tablas, el “max weight > 300” (real: 480), N de panel (2.926), N del SDM (141), artículos mapeados (236), y el párrafo “Ongoing work” sobre comisiones pendientes (desaparece).
4. **Cambio metodológico no documentado**: la propuesta original (`docs/research-proposal.tex`) prometía TERGM (M1) y SAOM/RSiena (M2); la implementación usa Valued ERGM y panel FE. Documentar la justificación (tamaño/estructura de los datos; identificación de selección vs. influencia vía FE + falsificación) en el README y en la próxima versión del paper.

P14 — Copias de insumos desincronizadas entre repos [RESUELTO 2026-07-07]

Regla instaurada: **este repo consume snapshots versionados de CPT; ningún script lee de CPT en runtime.** El snapshot `data/raw/dataverse-final/` (CPT paper-draft @ 5852519) incluye README de procedencia, codebook y `QA-report.txt`; se refresca copiando desde CPT y corriendo `code/0a-verify-dataverse-snapshot.py`. Los perfiles curados viven en `data/raw/conventional-profiles.json` (P5). Las carpetas `data/raw/commissions/` y `data/raw/network-visualization/` quedan como legacy de solo-lectura para comparación con los resultados pre-actualización.

P15 — C2 sin autores: no podía entrar a la red de co-patrocinio [RESUELTO aguas arriba 2026-07-07, ronda 2]

Situación original (QA 2026-07-07 a.m.). C2 no tenía `authors` en ninguna parte utilizable (0/312 GENESIS, 0/182 artículos TRACK_full); C4 tenía un hueco parcial (135/167, sin `sources` para el join).

Resolución (CPT paper-draft 55fae5d → 6fac4c4). `authors` poblado con la misma regla con que se construyó el resto del dataset — autores = firmantes de la(s) iniciativa(s) en `sources` (C2, 401 registros; regla validada 1.252/1.253 contra C3/C5/C6/C7) y vía `icc_id` (C4, 39 registros; validada 163/163). Verificado en el snapshot refrescado: C2 149/182 y C4 150/167 artículos con autores; **1.676 artículos con ≥ 2 autores-persona** para la red génesis, con las 7 comisiones aportando; las 75.616 menciones siguen resolviendo al 100% (los nuevos autores vienen en formato canónico). Residuo irrecuperable documentado en el codebook: 134/2.019 (65 populares/indígenas — patrocinio institucional, no de convencionales —, 45 de ICC ausentes del pool de PDF, 24 sin referencia de fuente).

Nota de alcance para M2. El `history[]` de C2 sigue delgado (33/54 entradas utilizables) y C2 no tiene indicaciones sueltas: C2 entra plenamente a M1 (génesis) y M3 (éxito), pero sus ondas en M2 aportarán poca variación intra-comisión — esperable y no bloqueante.

6. Decisiones de diseño confirmadas

Fecha	Decisión
2026-07-06	<code>coincidencias_comisiones.csv</code> (UTF-8) es la fuente de verdad del mapeo génesis→borrador final (P7).
2026-07-06	M1 = red génesis pura , 7 comisiones. Indicaciones solo en las ondas de M2. Génesis+indicaciones como robustez (P2).
2026-07-06	M3 : DV principal con ART-FALLIDO = 0 ($y' = \hat{s} \cdot \bar{r}$); DV condicional antigua como robustez (P6). W y centralidades sobre la red génesis (P9).

Fecha	Decisión
2026-07-06	M2: exposición acumulada desde T0 hasta $t - 1$ como especificación principal; robustez con decaimiento exponencial y con ventana solo-última-onda; sensibilidad estandarizando $\Delta\theta$ por días entre ondas.
2026-07-06	Indicaciones sueltas: entran a las ondas de M2 (timestamp+authors), no a M1 ni a M3; títulos se descartan (P8).
2026-07-06	Numeración oficial de comisiones confirmada; rótulos temáticos del paper a corregir (P13.1).
2026-07-06	Scraper BCN corregido y re-ejecutado: 154/154 perfiles (P5).
2026-07-06	Auditoría P5 vía gemini-3.5-flash (BCN + Wikipedia independientes, lotes de 5, situación al momento de la CC); símbolos $=/\neq/B/W/\emptyset$ por celda; validación humana antes de regenerar covariables.
2026-07-06	Arreglos que corresponden al repo CPT registrados en CPT-arreglos-pendientes.txt (raíz); se abordarán en ese repositorio.
2026-07-07	Grado académico pasa a escala ordinal 0-3 (sin estudios universitarios terminados / educación superior terminada / magíster / doctorado) y entra a M1 como absdiff (distancia educativa).
2026-07-07	Imputación automatizada de covariables: BCN ground truth $\rightarrow$ Wikipedia $\rightarrow$ base; manual_validations.json siempre prevalece. data/raw/conventional-profiles.json es el archivo curado canónico (154).
2026-07-07	Snapshot dataverse-final ingerido (CPT paper-draft @ 5852519) con test de aceptación 0a; regla P14 instaurada. Infraestructura de Fase 0 creada: paths.py/paths.R , lib_names.py/lib_names.R .
2026-07-07	Las referencias a iniciativas populares en authors se clasifican como no-persona y quedan fuera de la red de co-patrocinio.
2026-07-07	Actualización con C1 y C3 a C7 $\rightarrow$ ronda 2 de CPT resolvió P15: las 7 comisiones entran a la actualización (snapshot @ 6fac4c4).
2026-07-07	Registros sin fecha (“undated”) y residuo de 134 sin autores: documentados, no imputados; se excluyen de las ondas / de la red según corresponda.
2026-07-07	Unidad de co-firma: INICIATIVA como especificación principal, artículo como robustez (preferencia del usuario; ver §6.1).
2026-07-07	C2 se usa en M2 pese a sus ondas delgadas (naturaleza distinta de la comisión); documentado como limitación §4.4.
2026-07-07	Indicaciones repetidas en el history[] de varios artículos se colapsan a un acto de co-firma (dedup por autores+fecha+contenido).

Fecha	Decisión
2026-07-07	Pipeline v2 ejecutado completo (00–08); resultados en §4.3 y <code>results/tables/</code> .

6.1 Puntos a revisar (no son problemas P)

1. **Unidad de co-firma iniciativa vs. artículo.** La especificación principal usa iniciativa (cada documento co-firmado cuenta una vez); la de artículo pondera por el número de artículos de la iniciativa. Los resultados de M1 son cualitativamente iguales bajo ambas (ver `M1_robustness.csv`) y M3 mantiene $\rho \approx 0.93$ con W -artículo, pero conviene visitar la elección al escribir el paper (interpretación del peso w_{ij}).
2. **Interpretación del vuelco de H1b.** Con datos corregidos, la homofilia de abogados/experimentados pasó de negativa a positiva (§4.3.2): decidir cómo narrarlo en el paper (corrección de un artefacto de medición de la $v1$) y si mantener el marco de *gatekeeping* como hipótesis rechazada o reformularlo.
3. $\lambda = 0.5$ **del decaimiento en M2** es una elección de conveniencia; si la robustez de ventana entra al paper, barrer $\lambda \in \{0.25, 0.5, 0.75\}$.

7. Plan de actualización

- **Fase 0 — Infraestructura: completada** (2026-07-07): snapshot `dataverse-final` versionado + QA de aceptación (`0a-verify-dataverse-snapshot.py`); perfiles curados 154; `paths.py/paths.R`; `lib_names.py/lib_names.R` con validación al 100%. (*P14 cerrado; P3 y P4 quedan en su mitad de recableado de scripts.*)
- **Fase 0b — Calidad de covariables: completada** (2026-07-07): auditoría dual-fuente $v1+v2$, validación manual, e imputación automática con capa de validaciones humanas; `data/raw/conventional-profiles.json` regenerado con 154 perfiles curados. (*P5 cerrado.*)
- **Fase 1 — Loader unificado: completada** (2026-07-07) dentro del script 00 v2: lector GENESIS (2 esquemas), clasificación artículo/indicación-suelta, dedup de indicaciones repetidas, parseo de timestamps. (*P8 cerrado en su parte de loader.*)
- **Fase 2 — Redes: completada** (2026-07-07): red génesis-iniciativa pooled (528 iniciativas, decisión §6.1) + red artículo de robustez + ondas $\times 7$ con bins observados. (*P1-red y P2 cerrados.*)
- **Fase 3 — Modelos: completada** (2026-07-07): M1 ERGM (iniciativa + robusteces), M2 panel de 4.278 obs con falsificación y ventanas, M3 SDM con coincidencias, DV y' y W -génesis. Resultados en §4.3. (*P1, P6, P7, P9 cerrados; P11 re-evaluado con la robustez por comisión.*)
- **Fase 4 — Integración y paper: parcial: integrated_dataset** con exactamente 154 filas, suite de robustez y tablas exportadas a `results/tables/` (hechos); **pendiente:** figuras y la actualización del extended abstract y README (cifras nuevas, rótulos oficiales, narrativa del vuelco de H1b, eliminar “ongoing work”). (*P12 parcial; P13 abierto.*)

8. Registro de cambios de este documento

- **v2.0 (2026-07-07).** Re-ejecución completa del estudio con las 7 comisiones (pipeline v2, scripts 00–08 reescritos sobre `paths/lib_names`): red génesis-INICIATIVA (528 iniciativas; decisión §6.1), panel M2 de 4.278 obs, M3 con DV y' y $N = 154$ completos. Nuevas §3.4 (regla de perfiles), §4.3 (resultados v2), §4.4 (limitaciones, incl. C2 delgada) y §6.1 (puntos a revisar). Hallazgos: H1a reforzada; **H1b invertida** (homofilia positiva de abogados/experiencia; el gatekeeping de la $v1$ no sobrevive la corrección de datos); nueva estratificación educativa (absdiff grado -0.048); H2 replicada y blindada (FE nulo + falsificación + 3 ventanas); H3 amplificada (Moran 0.38, ρ 0.94, robusta a 4 variantes). P1–P4, P6, P7, P9 cerrados; P12 parcial.
- **v1.4 (2026-07-07).** Ronda 2 de CPT ingerida (snapshot @ `6fac4c4`): P15 resuelto (authors de C2 vía `sources`→firmantes y C4 vía `icc_id`; 1.676 artículos con ≥ 2 autores; residuo 134 documentado),

timestamps *undated* documentados (P8.4). QA re-ejecutado: 75.616 menciones, 100% resueltas. Las 7 comisiones entran a la actualización; luz verde para reescribir el pipeline.

- **v1.3 (2026-07-07)**. Fase 0 completada: snapshot **dataverse-final** ingerido (CPT **paper-draft @ 5852519**; TRACK_full 2.019, 210 indicaciones sueltas, uid/final_status 100%), test de aceptación 0a, módulos **paths** y **lib_names** (70.043 menciones de autor validadas al 100%, con filtro de iniciativas populares). P14 cerrado; P3/P4/P8 avanzados a parcial; **nuevo P15**: C2 sin **authors** (bloqueado en CPT). §3 reescrita con las cifras del snapshot.
- **v1.2 (2026-07-07)**. P5 cerrado: corrida v2 de la auditoría (lotes de 6, grado 0–3, **profiles-batches/**), chequeo de consistencia v1 vs. v2, e imputación automatizada (BCN → Wikipedia → base, con **manual_validations.json** prevaleciendo); **data/raw/conventional-profiles.json** regenerado (154 perfiles curados, 0 “Desconocida”). Decisión de modelo: **absdiff(grado académico 0--3)** se agrega a M1.
- **v1.1 (2026-07-06)**. P5: auditoría dual-fuente BCN+Wikipedia ejecutada con **gemini-3.5-flash** (154/154; 135 discrepancias con el pipeline; tablas en **data/raw/profile-audit/**). Nuevo CPT-**arreglos-pendientes.txt** en la raíz con los arreglos que corresponden al repositorio de datos (P8, higiene, documentación).
- **v1 (2026-07-06)**. Versión inicial: objetivos y marco teórico (§2), inventario de datos nuevos (§3), pipeline y resultados vigentes (§4), registro detallado de problemas P1–P14 (§5), decisiones confirmadas (§6) y plan por fases (§7). Incluye el fix del scraper BCN (P5) aplicado en esta fecha.