

Modelos de eventos relacionales de hiperevento (RHEM)

Introducción pedagógica para el proyecto Networked Influence — de los ERGM y el logit condicional al modelado de co-firmas fechadas

Preparado a partir de los papers de arXiv de la familia Butts / Lerner–Lomi (verificación cruzada de fue

July 10, 2026

Contents

1. Para qué existe esta familia	1
2. El punto de partida: el REM de Butts (2008)	1
3. Por qué las díadas no bastan para la co-firma	2
4. El RHEM: tasas sobre conjuntos	2
4.1 La versión no dirigida (nuestra plantilla)	2
4.2 Homofilia y composición del grupo	3
4.3 Dos extensiones que conviene conocer	3
5. Estimación práctica: caso-control anidado	4
6. Software: evaluación y decisión	4
7. El modelo para la Convención, en una tabla	5
8. Lecturas, en orden recomendado	5

1. Para qué existe esta familia

Un ERGM responde “¿por qué la red se ve así?” mirando **una foto**. Nuestro dato real no es una foto: son **528 eventos fechados** — cada iniciativa es un instante en que un conjunto de 8–16 convencionales hizo algo juntos — y la foto la fabricamos nosotros al agregarlos. Al agregar se destruye la información más valiosa: el **orden** (quién firmó con quién *después* de qué) y con ella toda posibilidad de separar homofilia de historia (“firmo contigo porque nos parecemos” vs. “firmo contigo porque ya firmamos juntos”).

El **modelo de eventos relacionales** (REM) invierte el objeto: en vez de modelar la red, modela la **secuencia de eventos** como un proceso puntual en tiempo continuo, donde la tasa a la que cada evento posible ocurre depende de la historia acumulada y de covariables. Su extensión a eventos **multi-actor** — el **modelo de hiperevento relacional** (RHEM) — es la única familia estadística cuya unidad nativa es exactamente nuestro dato: un evento fechado protagonizado por un *conjunto* de actores, sin proyección a díadas y sin noción de “lazo que se disuelve”.

2. El punto de partida: el REM de Butts (2008)

Butts (2008, *Sociological Methodology*) modela secuencias de acciones diádicas ($i \rightarrow j$) con una **intensidad** (tasa instantánea) para cada díada posible:

$$\lambda_{ij}(t \mid A_t; \theta) = \exp\{\theta^\top s_{ij}(A_t, X)\} \cdot \mathbf{1}\{(i, j) \in \mathcal{R}(t)\}$$

Término a término: A_t es la **historia** (todos los eventos anteriores a t); $s_{ij}(A_t, X)$ es un vector de **estadísticas** calculadas sobre esa historia y sobre atributos exógenos X — por ejemplo *repetición* ($N_{ij}(t^-)$: cuántas veces i ya actuó sobre j), *reciprocidad* ($N_{ji}(t^-)$), *cierre transitivo* ($\sum_a N_{ia} N_{aj}$: amigos de amigos) y *homofilia* ($\mathbf{1}\{x_i = x_j\}$ o $-|x_i - x_j|$); θ son los parámetros, que se leen como en un logit (e^{θ_k} = factor multiplicativo de la tasa por unidad de estadística); y $\mathcal{R}(t)$ es el **conjunto de riesgo** (las díadas que *podrían* ocurrir en t).

Hay dos verosimilitudes. La **completa** usa los tiempos exactos entre eventos. La **ordinal** usa solo el *orden* — la relevante cuando se tienen fechas pero no horas, nuestro caso:

$$L_O(\theta) = \prod_{k=1}^n \frac{\exp\{\theta^\top s_{i_k j_k}\}}{\sum_{(i,j) \in \mathcal{R}(t_k)} \exp\{\theta^\top s_{ij}\}}$$

Cada factor responde: *dado que ocurrió un evento en t_k , ¿qué probabilidad tenía de ser exactamente esa díada y no cualquier otra en riesgo?* Esa es literalmente la forma de un **logit condicional de McFadden** (y coincide con la verosimilitud parcial de Cox estratificada por evento). Este es el puente pedagógico central del documento: el **REM ordinal es el logit condicional que ya usamos en M1 (IV.D1), con dos diferencias** — el “menú” es el conjunto de riesgo en cada instante, y las covariables pueden depender de la historia. El logit condicional de M1 es un REM con $\theta_{historia} = 0$.

3. Por qué las díadas no bastan para la co-firma

Una iniciativa con 16 firmantes no es un evento diádico. La salida ingenua — descomponerla en $\binom{16}{2} = 120$ díadas “simultáneas” — reproduce en el tiempo exactamente la patología D1 del ERGM proyectado: infla el número de observaciones con eventos que no son independientes, y además **no puede expresar las hipótesis interesantes**. “Este trío ya firmó junto tres veces” no es una función de díadas: vive en el subconjunto. Lerner, Tranmer, Mowbray y Hâncean (arXiv:1912.07403) lo formulan de modo quirúrgico para correos multi-destinatario: el REM diádico no distingue “Ana escribe a Berta y a Carlos por separado” de “Ana escribe al par {Berta, Carlos}” — y la sociología de equipos está en la segunda.

La solución es cambiar la unidad: el evento es $e = (t_e, h_e)$ donde $h_e \subseteq V$ es la **hiperarista** — el conjunto completo de actores del evento, de tamaño arbitrario. Para nosotros: iniciativa = hiperevento; h_e = los 8–16 firmantes; V = los 154 convencionales.

4. El RHEM: tasas sobre conjuntos

4.1 La versión no dirigida (nuestra plantilla)

Lerner & Hâncean (*Network Science* 2023; arXiv:2105.01562) modelan coautoría científica — equipos de tamaño variable que publican en fechas — con una tasa relativa sobre cada equipo posible h :

$$\lambda_1(t, h; \theta) = \exp\left(\sum_i \theta_i s_i(t, h, G[E; t])\right),$$

donde $G[E; t]$ es la red de eventos pasados. La verosimilitud parcial compara el equipo observado contra los equipos alternativos **del mismo tamaño**:

$$L(\theta) = \prod_{e \in E} \frac{\lambda_1(t_e, h_e; \theta)}{\sum_{h \in R_{t_e}} \lambda_1(t_e, h; \theta)}, \quad R_{t_e} = \text{hiperaristas candidatas con } |h| = |h_e|.$$

Condicionar en el tamaño es la decisión de diseño clave: el modelo **no** explica *cuántos* firman (eso lo fija la regla 8–16) sino *cuáles* — el análogo exacto de nuestro `strata(iniciativa)` en el clogit y del `constraints = ~b2degrees` en el ERGM bipartito.

Las estadísticas de historia se construyen con una sola pieza: el **grado de hiperarista** de un subconjunto h' ,

$$\deg(t, h') = \sum_{e \in E_{<t}} \chi(h' \subseteq h_e) \quad (\text{¿en cuántos eventos pasados apareció junto ese subconjunto?}),$$

opcionalmente con **decaimiento exponencial** $w(\Delta) = \exp(-\Delta \ln 2 / T_{1/2})$ ($T_{1/2}$ = semivida: un evento de hace $T_{1/2}$ días pesa la mitad que uno de hoy — la versión principled de nuestras ventanas de exposición de M2). Sobre él se define la **repetición de subconjuntos de orden p** :

$$\text{sub.rep}^{(p)}(t, h) = \frac{1}{\binom{|h|}{p}} \sum_{h' \in \binom{h}{p}} \deg(t, h'),$$

el promedio del grado histórico de los subconjuntos de tamaño p del candidato h . Término a término: con $p = 1$ es la **actividad** media de los firmantes (¿los que más firman siguen firmando? — apego preferencial); con $p = 2$ es la **familiaridad diádica** media (¿pares que ya co-firmaron?); con $p = 3$, la **triádica** (¿tríos consolidados? — esto es lo que ninguna diáda puede expresar). Y el **cierre**:

$$\text{closure}(t, h) = \frac{1}{\binom{|h|}{2}} \sum_{\{u, v\} \in \binom{h}{2}} \max_{w \neq u, v} \min[\deg(t, \{u, w\}), \deg(t, \{v, w\})]$$

— para cada par del equipo, ¿existe un colaborador común fuerte w ? (cierre triádico en versión hipergráfica: “los amigos de mis co-firmantes acaban firmando conmigo”).

4.2 Homofilia y composición del grupo

El paper de referencia formal (Lerner & Lomi, *JRSS-A* 2023; arXiv:2112.10552, versión dirigida “multicast”) aporta el catálogo de covariables **de composición** sobre un atributo z : el promedio del conjunto ($\sum_{j \in h} z_j / |h|$), la diferencia con un actor focal, y — la que usaremos como homofilia ideológica del grupo — la **dispersión interna** del conjunto sobre z (suma de $|z_j - z_{j'}|$ sobre pares del equipo). Con $z = \theta_1^{fm}$ eso es exactamente “¿cuán ideológicamente compacta es la coalición firmante?”; con indicadores de lista/profesión, la proporción de pares coincidentes. Son nuestras covariables del clogit de M1, ahora acompañadas de las estadísticas de historia.

4.3 Dos extensiones que conviene conocer

- **Dos modos** (Lerner, Hâncean & Lomi, *JRSS-A* 2025; arXiv:2308.01722): el evento es un par de conjuntos (I, J) — autores y referencias citadas — con la estadística maestra $\text{subrep}^{(k, \ell)}$ que generaliza todas las anteriores. Para nosotros abre la puerta a modelar (firmantes, contenido) si algún día queremos preguntar si subgrupos se especializan en “paquetes temáticos”.
- **RHOM** — *relational hyperevent outcome model* (mismo paper de coautoría): condicional a que el equipo se formó, un segundo modelo predice el **resultado** del evento (allí, citas; aquí, supervivencia del texto) **con las mismas estadísticas de hiperarista**. Es la unificación natural de M1 (formación) con M3/M4 (éxito) en un solo lenguaje: ¿lo que junta a las coaliciones es también lo que las hace ganar?
- Precedente regional: Espinosa-Rada, Lerner & Fritz (arXiv:2407.21067) aplican el RHEM orientado a grupos a astrónomos chilenos — cita útil de factibilidad.

5. Estimación práctica: caso-control anidado

El conjunto de riesgo es astronómico: hay $\binom{154}{12} \approx 10^{17}$ coaliciones posibles de tamaño 12. Nadie suma ese denominador. La práctica estándar (Lerner & Lomi, *Network Science* 2020; arXiv:1905.00630 — validada con 360 millones de eventos de Wikipedia) es el **muestreo caso-control**: para cada evento observado (el *caso*) se sortean m hiperaristas contrafactuales del mismo tamaño (los *controles*), y se estima

$$\Pr(h_e \mid \text{historia}) = \frac{\exp\{\theta^\top s(h_e)\}}{\exp\{\theta^\top s(h_e)\} + \sum_{\tilde{h} \in \text{controles}} \exp\{\theta^\top s(\tilde{h})\}}$$

— un logit condicional 1: m por estrato. La teoría de *nested case-control* (Borgan–Goldstein–Langholz) garantiza consistencia aunque m sea pequeño; el costo es solo varianza. Crucial: **las estadísticas de historia se calculan sobre TODOS los eventos pasados**, no solo los muestreados — se muestrea el denominador, nunca la historia.

Advertencias prácticas de esa literatura, aplicadas a nuestro caso:

1. **Los efectos de repetición son los que más controles necesitan** (están concentrados en pocas coaliciones). Con solo 528 eventos podemos ser generosos: $m = 50\text{--}100$ controles por evento cuesta segundos, no horas.
2. **Estandarizar** las estadísticas (media 0, DE 1) antes de ajustar, para comparabilidad de coeficientes.
3. **Re-estimar sobre varias muestras independientes de controles** (5–10) y reportar la estabilidad de $\hat{\theta}$ — el análogo del “seed sensitivity check”.
4. **Empates de fecha**: muchas iniciativas comparten día. La verosimilitud ordinal admite empates a la Efron (como nuestro clogit); la historia se congela al inicio del día (los eventos del mismo día no se ven entre sí) — la misma convención `event_hash`/dedup del pipeline.
5. El **riesgo** debe reflejar elegibilidad real: convencionales activos a la fecha (el roster de 154 es estable; la vacante de Rojas Vade ya está fuera).

6. Software: evaluación y decisión

Herramienta	Dónde	¿Hipereventos?	Veredicto
amorem (Richter, Boschi, Wit, Lembo)	CRAN v1.0.0 (2026-06-29) + GitHub	Sí (<code>hyperedge_log</code> , <code>hyperedge_features</code> : <code>subrep_1/2/...</code> , <code>activity</code>)	Elegido — ver abajo
eventnet (Lerner)	Java, GitHub	Sí (referencia del campo)	Plan B / verificación cruzada
relevent / rem / remstats	CRAN	No (diádicos)	No aplica a co-firma
goldfish (DyNAM, Stadtfeld)	CRAN	Parcial (coordinación)	Modela elecciones de actor individual; menos natural para un equipo simultáneo

La decisión (2026-07-10), tras verificación con instalación y benchmark local. `amorem` (“Augmented Modelling of Relational Events”) **está en CRAN** — v1.0.0 publicada el 2026-06-29, checks de CRAN limpios, 50 archivos de test, y viene del mismo grupo que la literatura RHEM (Boschi, Lerner & Wit 2025, arXiv:2509.05289). Verificado en esta máquina: `hyperedge_log(I, J, time)` acepta exactamente nuestro formato (conjuntos de firmantes, no dirigido), `hyperedge_features()` calcula `subrep_1` (actividad), `subrep_2` (familiaridad diádica) y `activity` (repetición del conjunto completo), y `rem(..., method`

= "clogit", case =, stratum =) estima la verosimilitud caso-control con `survival::clogit` — ajuste en centésimas de segundo.

Lo que falta y cómo se cubre (la “capa fina”, ~100 líneas): (a) el muestreador de controles de `amorem` es solo diádico → sortear nosotros m coaliciones del mismo tamaño entre los 154 (unas 20 líneas); (b) las covariables de composición (dispersión ideológica del grupo, proporción misma lista, misma comisión) se calculan a mano por candidato — ya lo hacemos en el clogit de M1; (c) el `closure` poliádico no está en el catálogo → codificarlo sobre el log si un revisor lo pide, o correr `eventnet` una vez como verificación.

Sobre la paralelización — la respuesta a la duda del autor: el benchmark con la forma exacta de nuestros datos (528 eventos, 8–16 de 154) da **41 s en un solo core** con 5 controles por evento; con 50 controles, ~5–10 min secuencial, y ~1 min envolviendo el loop por estratos en `parallel::mclapply(mc.cores = 8)` — porque cada estrato es independiente dada la historia observada. El ajuste en sí tarda centésimas de segundo. **No existe la “ganancia enorme” que justificaría una implementación propia:** vamos con el paquete, versión fijada (`renv`), con un sanity check de `subrep` contra cálculo manual en 2–3 eventos.

7. El modelo para la Convención, en una tabla

Especificación propuesta (RHEM no dirigido, ordinal, estratificado por tamaño; $m = 50$ controles; $T_{1/2} = 30$ días como base y ∞ como robustez):

Estadística	Qué mide	Hipótesis del proyecto
dispersión de θ_1 (y θ_2) en h	compacidad ideológica de la coalición	homofilia (M1): $\theta < 0$
prop. de pares misma lista en h prop. de firmantes de la comisión del texto	coordinación de lista estructura de oportunidad	λ_{lista} dinámico (D2.3: ¿persiste?) D10
$sub.rep^{(1)}$	actividad previa de los firmantes	firmantes seriales (F9a)
$sub.rep^{(2)}$	pares que ya co-firmaron	selección (la hipótesis H2 en su forma nativa)
$sub.rep^{(3)}$	tríos consolidados	coaliciones-núcleo (invisible para diádas)
$closure$	co-firmantes de mis co-firmantes	cierre (el <code>gwersp</code> temporal)

Lectura de conjunto: **este único modelo unifica M1 y M2 en un solo reloj** — la homofilia es el efecto de los atributos, la selección es el efecto de la historia, y ambos se estiman juntos sin proyección, con el N honesto y con el tiempo fino que el panel de ondas discretiza. El paso siguiente natural (RHOM) reutiliza las mismas estadísticas para predecir supervivencia del texto, conectando con M3/M4.

8. Lecturas, en orden recomendado

1. **Bianchi, Filippi-Mazzola, Lomi & Wit (2024)**, “Relational Event Modeling”, *Annu. Rev. Stat. Appl.* 11:297–319 — arXiv:2306.17581. *El survey; el puente desde ERGMs.*
2. **Butts (2008)**, “A Relational Event Framework for Social Action”, *Sociol. Methodol.* 38:155–200. *El fundacional (no está en arXiv).*
3. **Lerner & Hâncean (2023)**, “Micro-level network dynamics of scientific collaboration and impact”, *Network Science* 11:5–44 — arXiv:2105.01562. *Nuestra plantilla exacta (coautoría, no dirigido, RHOM).*
4. **Lerner & Lomi (2023)**, “Relational hyperevent models for polyadic interaction networks”, *JRSS-A* 186:577–600 — arXiv:2112.10552. *El aparato formal completo.*
5. **Lerner & Lomi (2020)**, “Reliability of relational event model estimates under sampling”, *Network Science* 8:97–135 — arXiv:1905.00630. *La justificación del caso-control.*
6. **Lerner, Tranmer, Mowbray & Hâncean (2019)**, “REM beyond dyads” — arXiv:1912.07403. *La motivación anti-diáda, corta.*

7. **Lerner, Hâncean & Lomi (2025)**, “RHEM for the coevolution of coauthoring and citation networks”, *JRSS-A* 188:583–607 — arXiv:2308.01722. *La generalización subrep^(k,ℓ), dos modos.*
8. **Espinosa-Rada, Lerner & Fritz (2024/25)**, “Socio-cognitive networks between researchers” — arXiv:2407.21067. *RHEM aplicado a un caso chileno.*